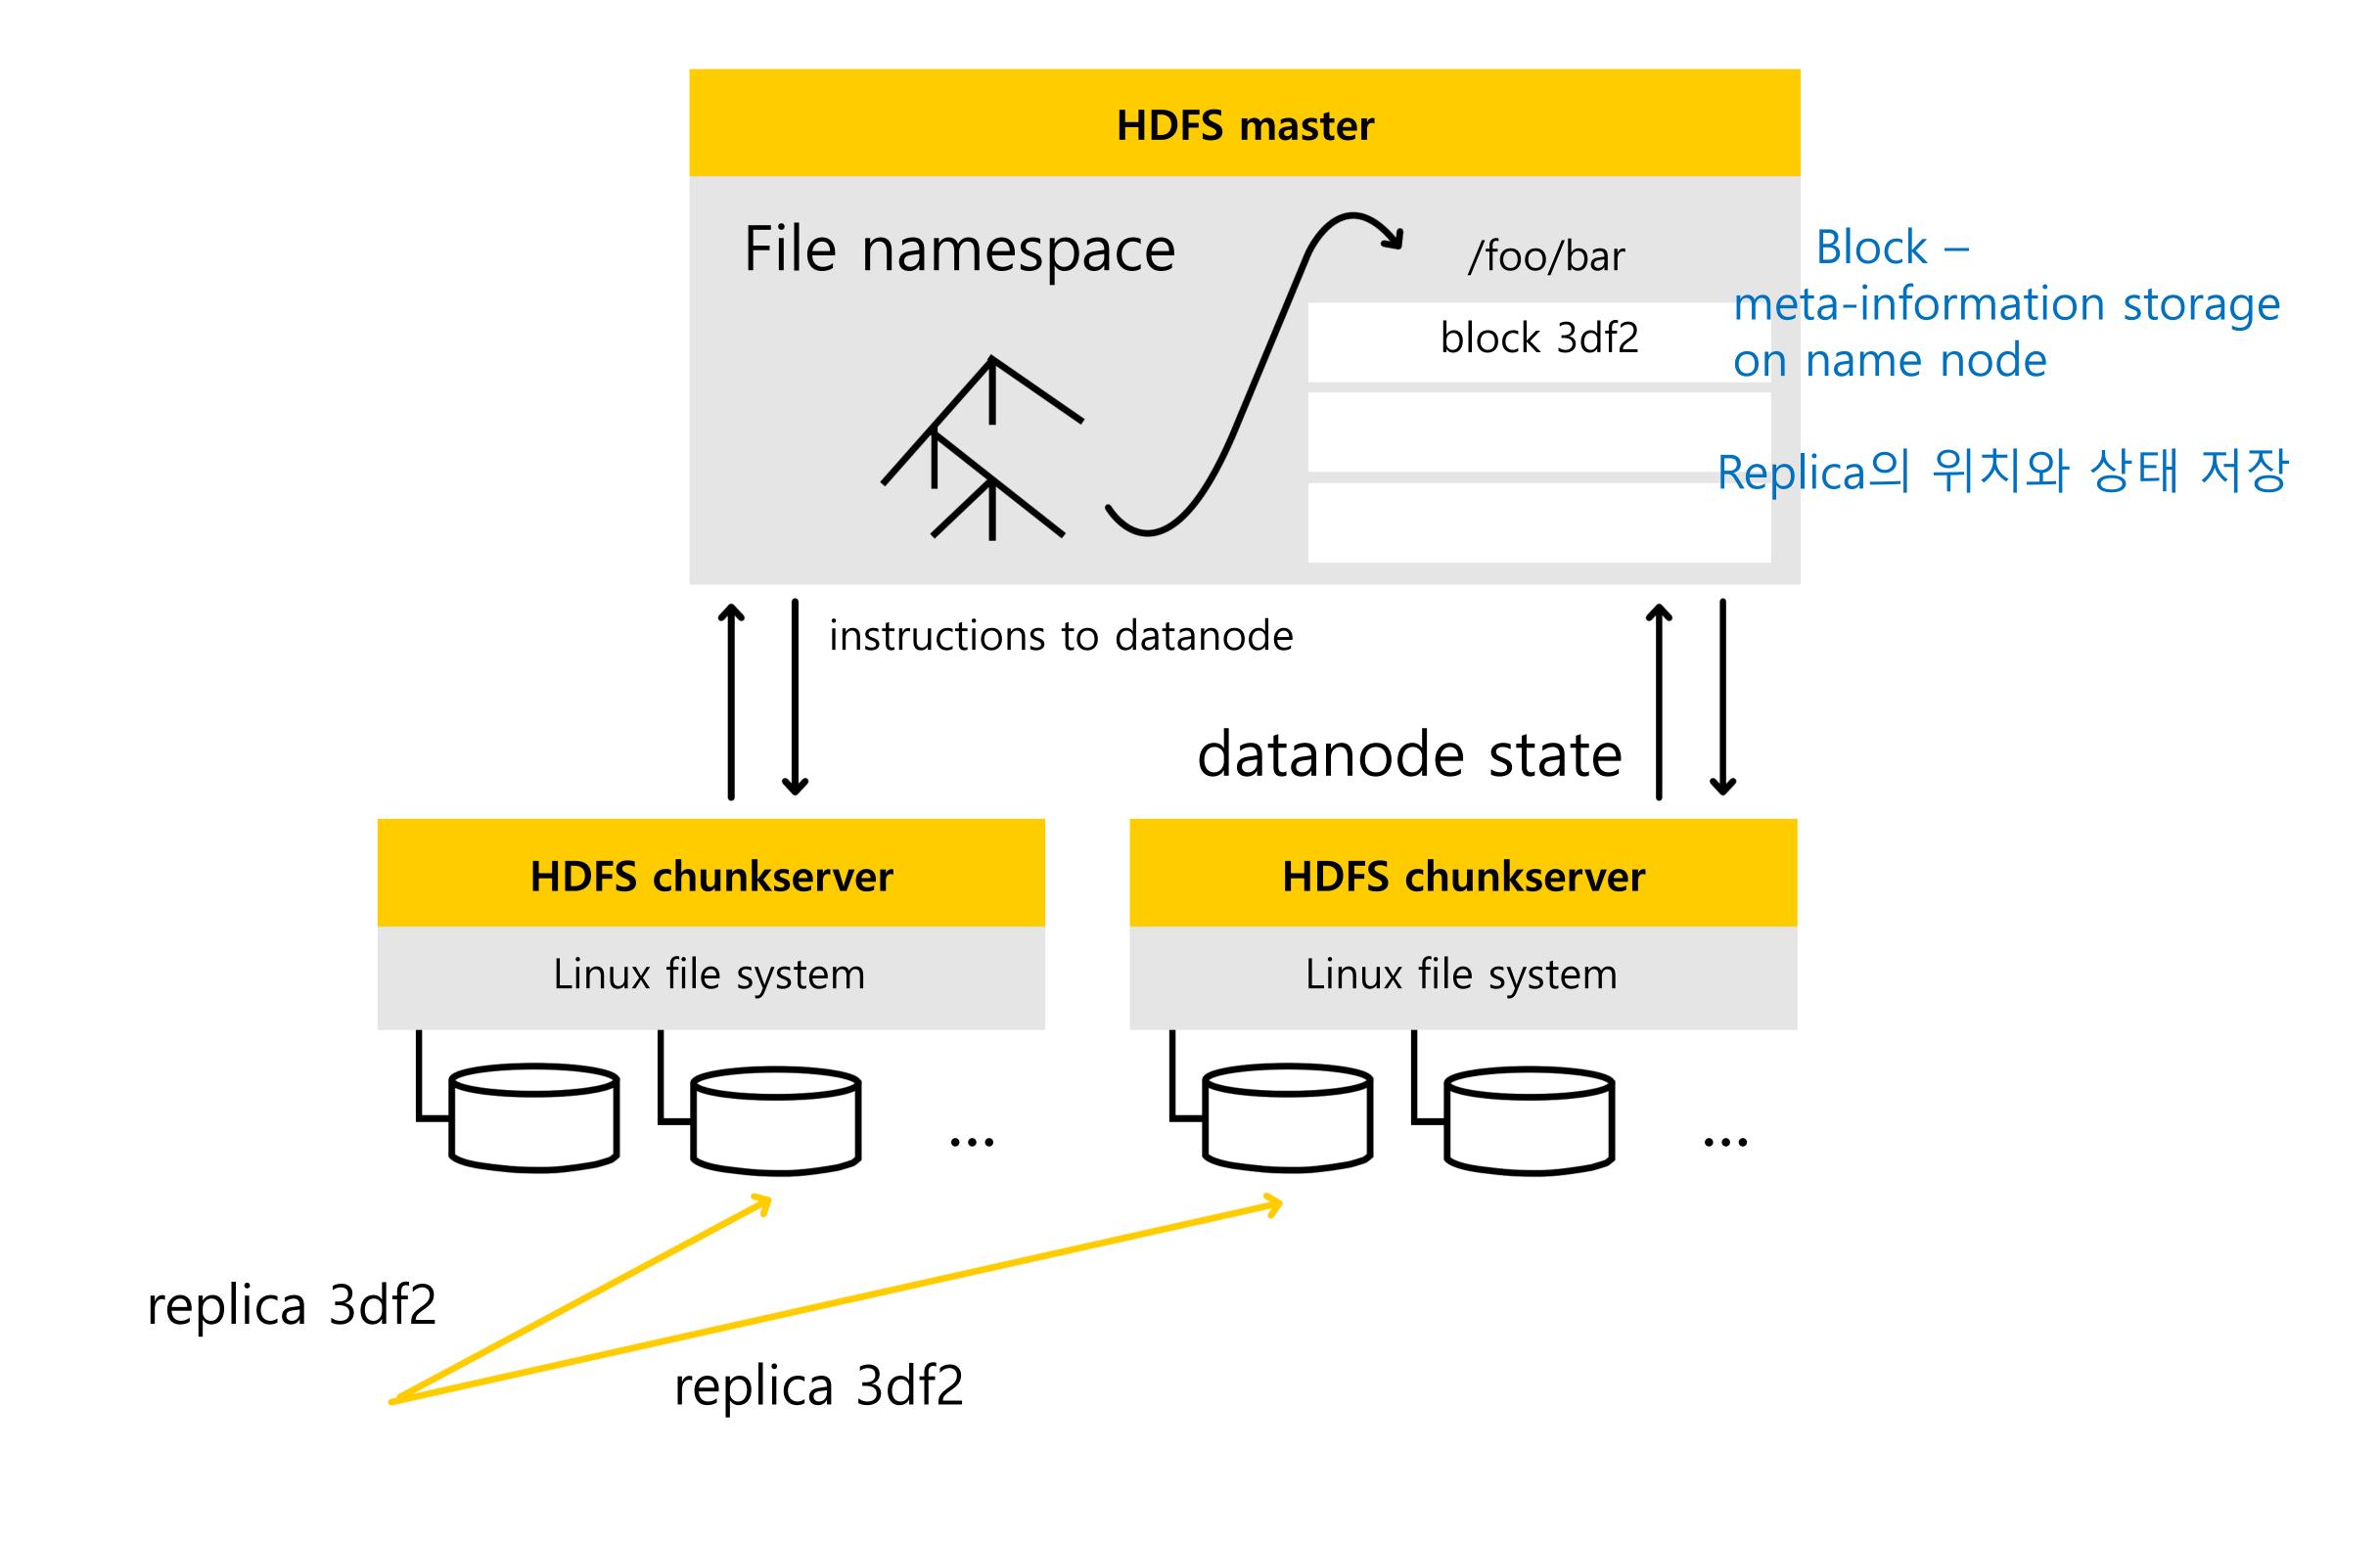
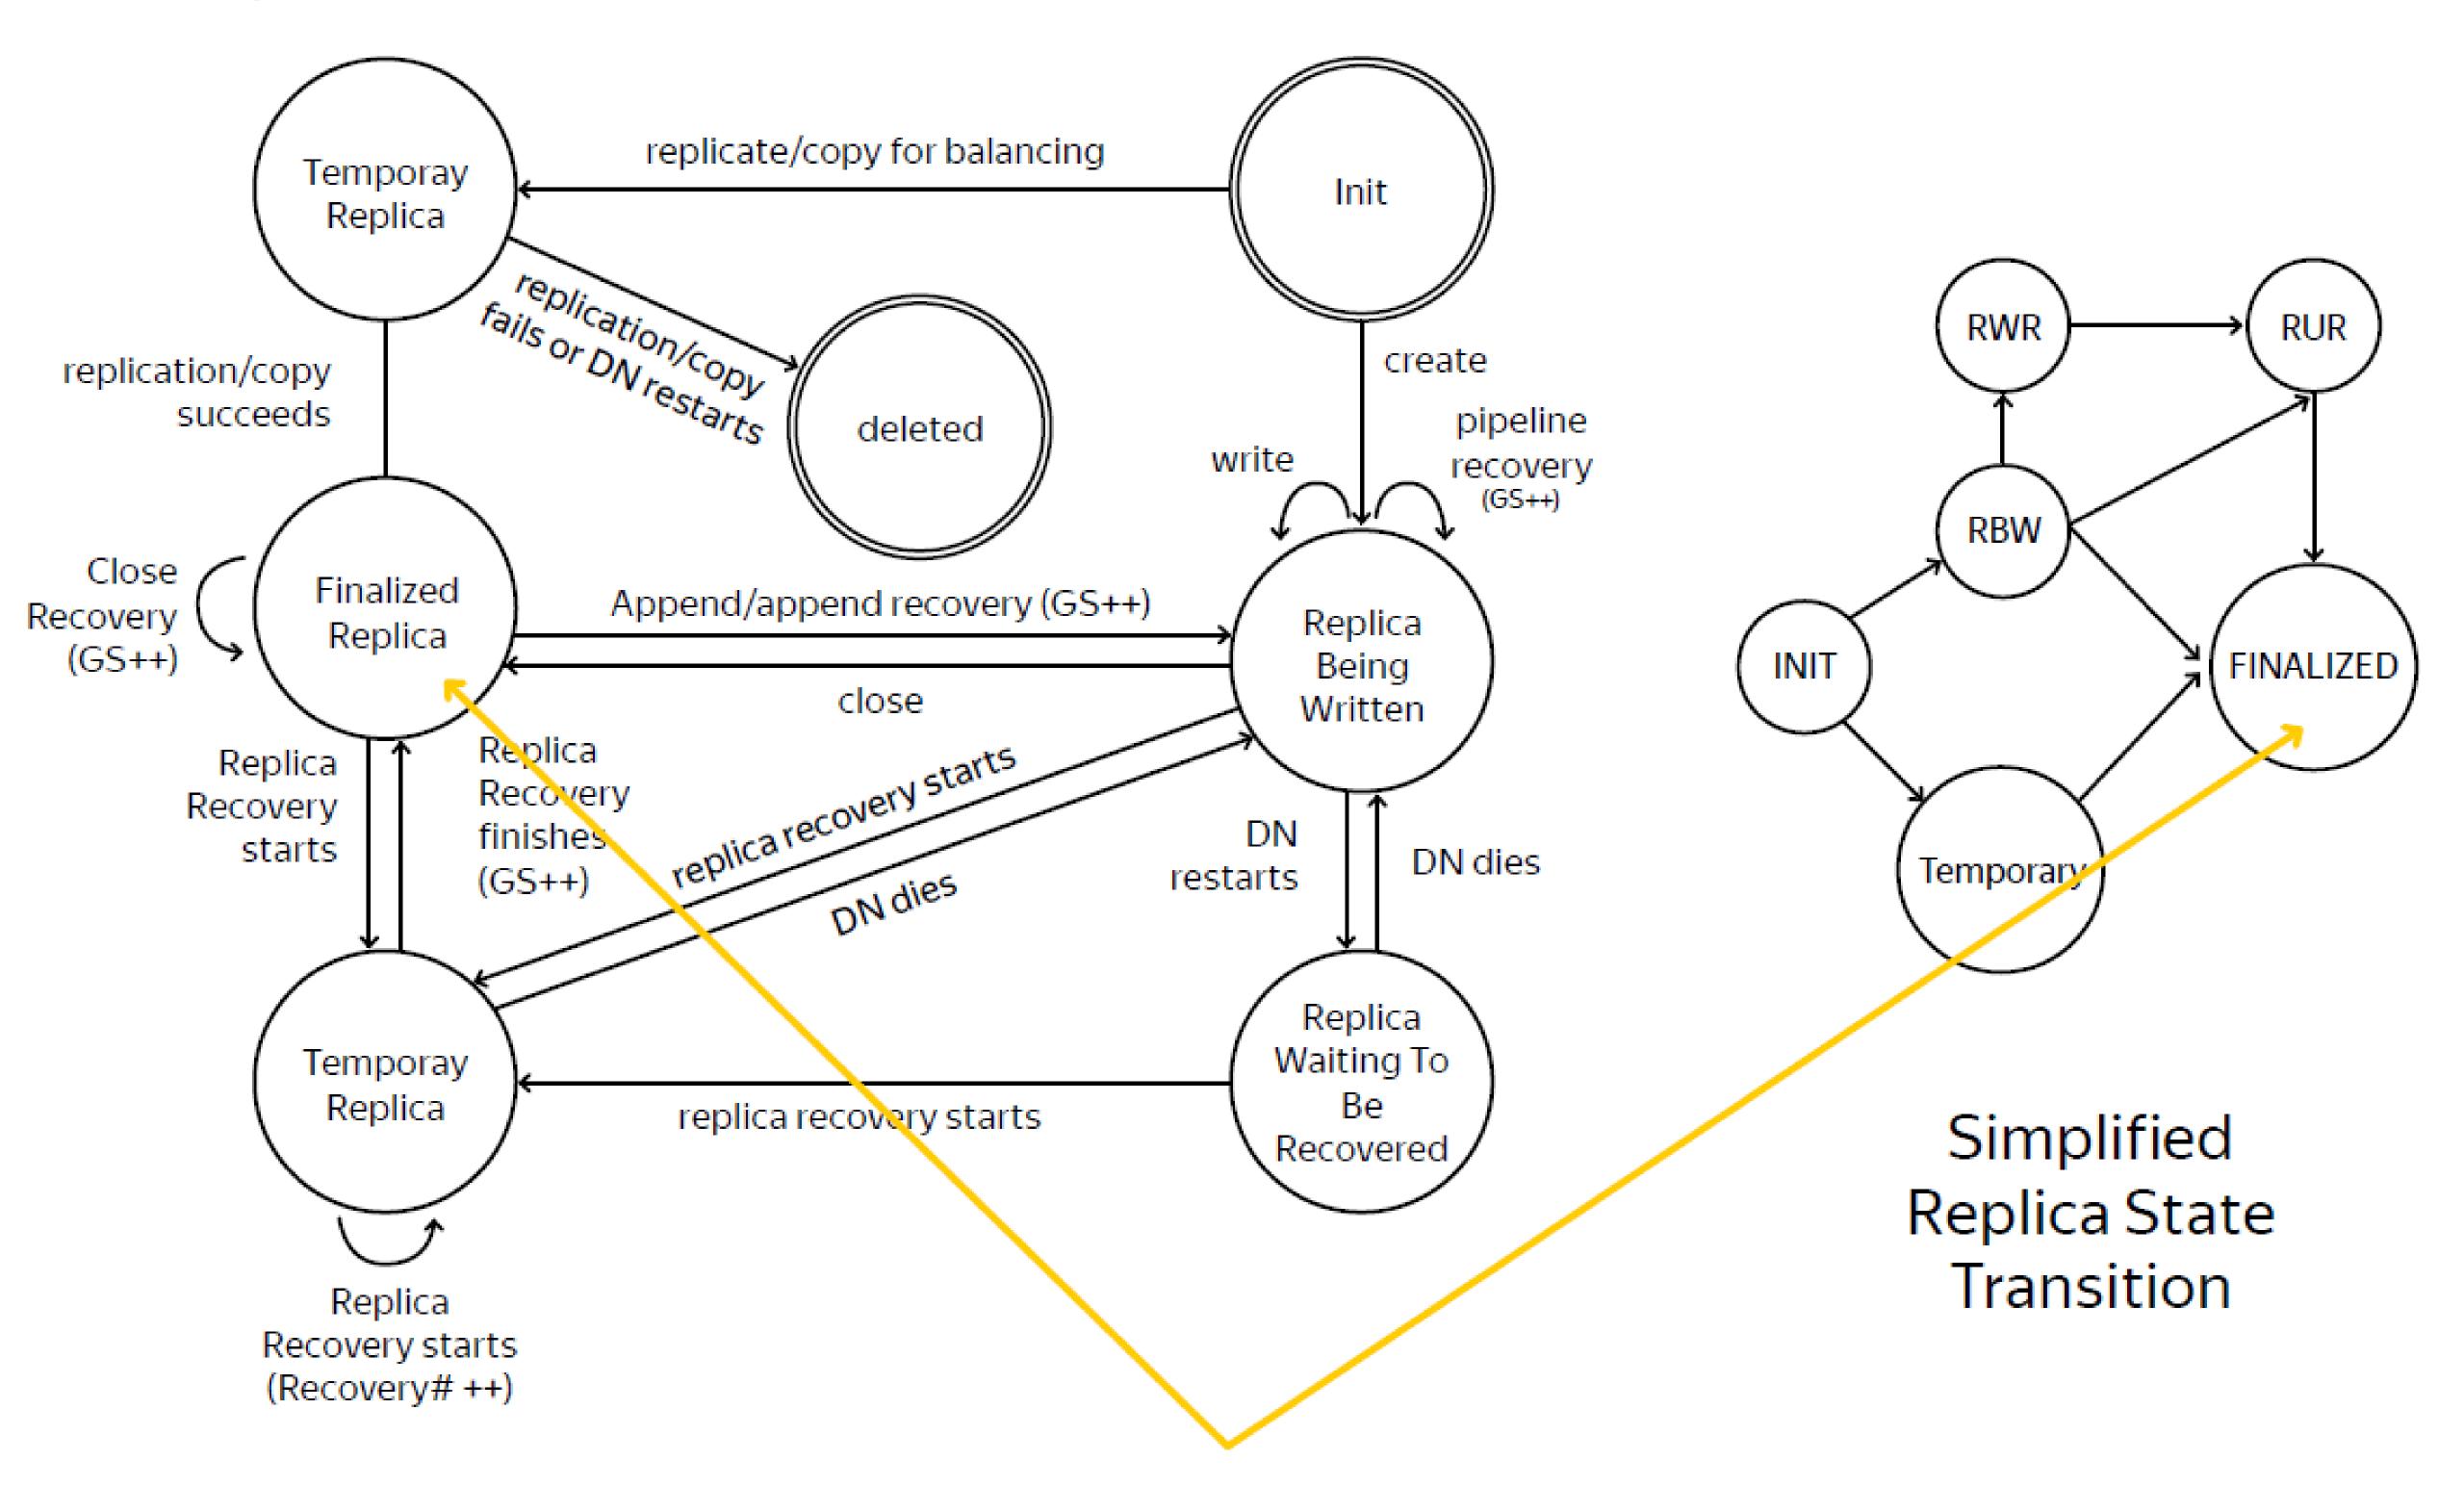
# Vandex

## HDFS

Block and Replica States, Recovery Process



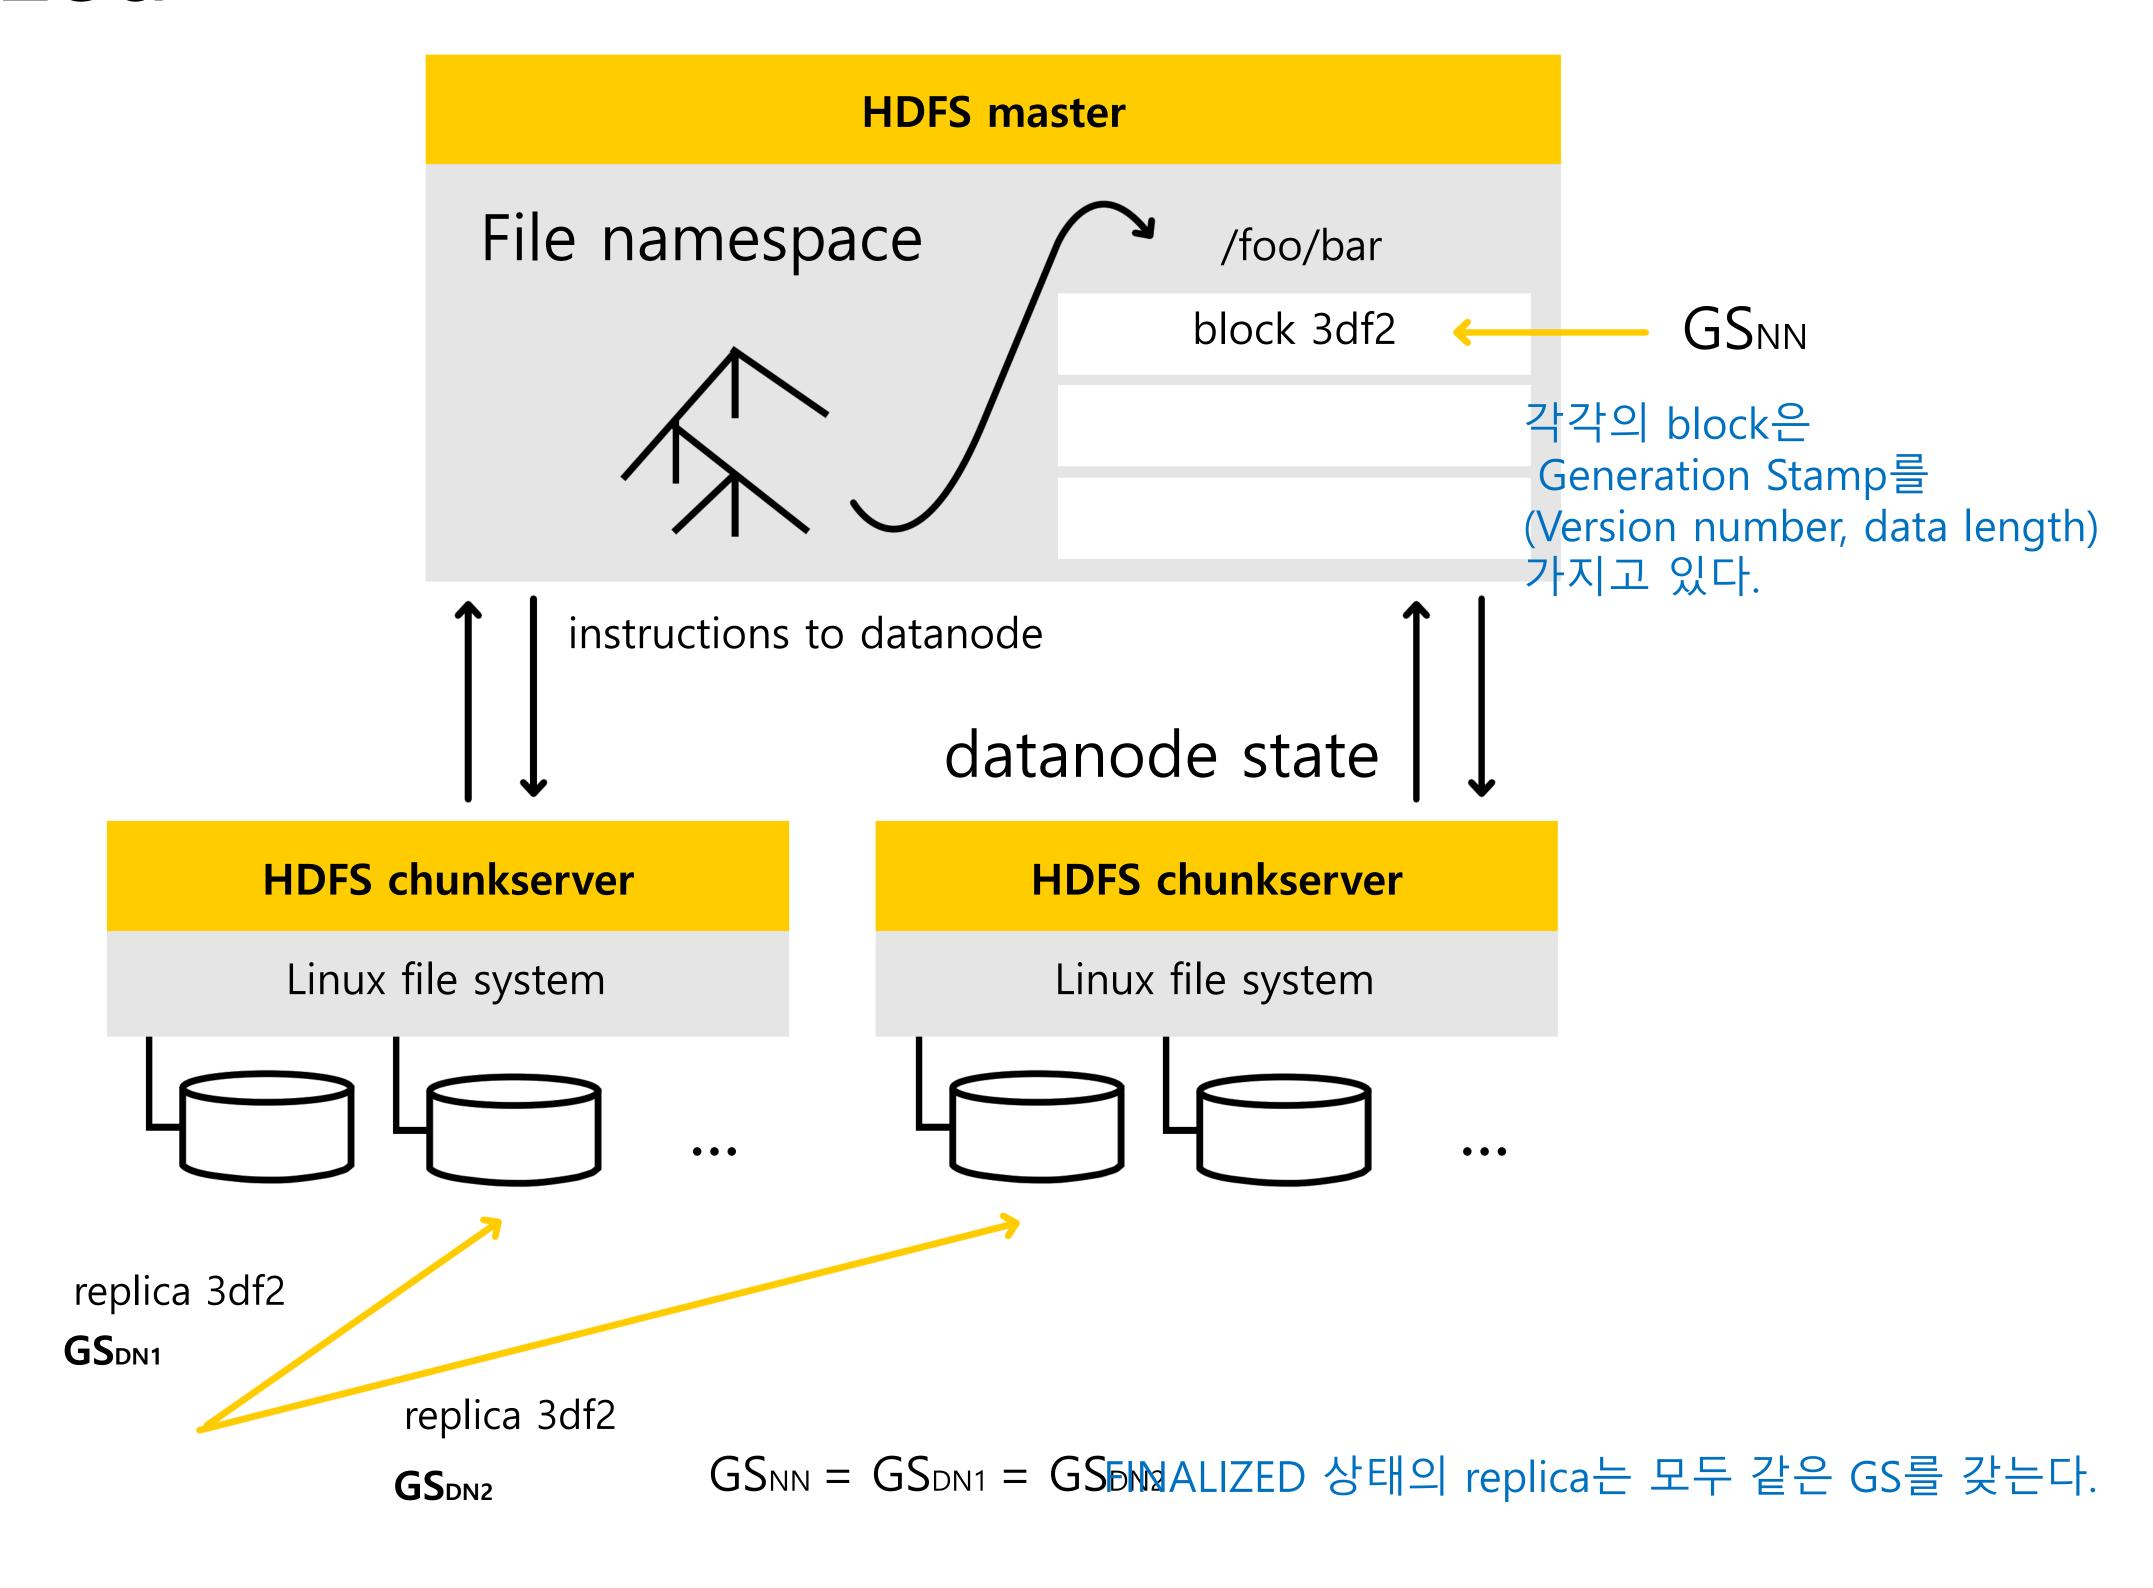
#### Replica state

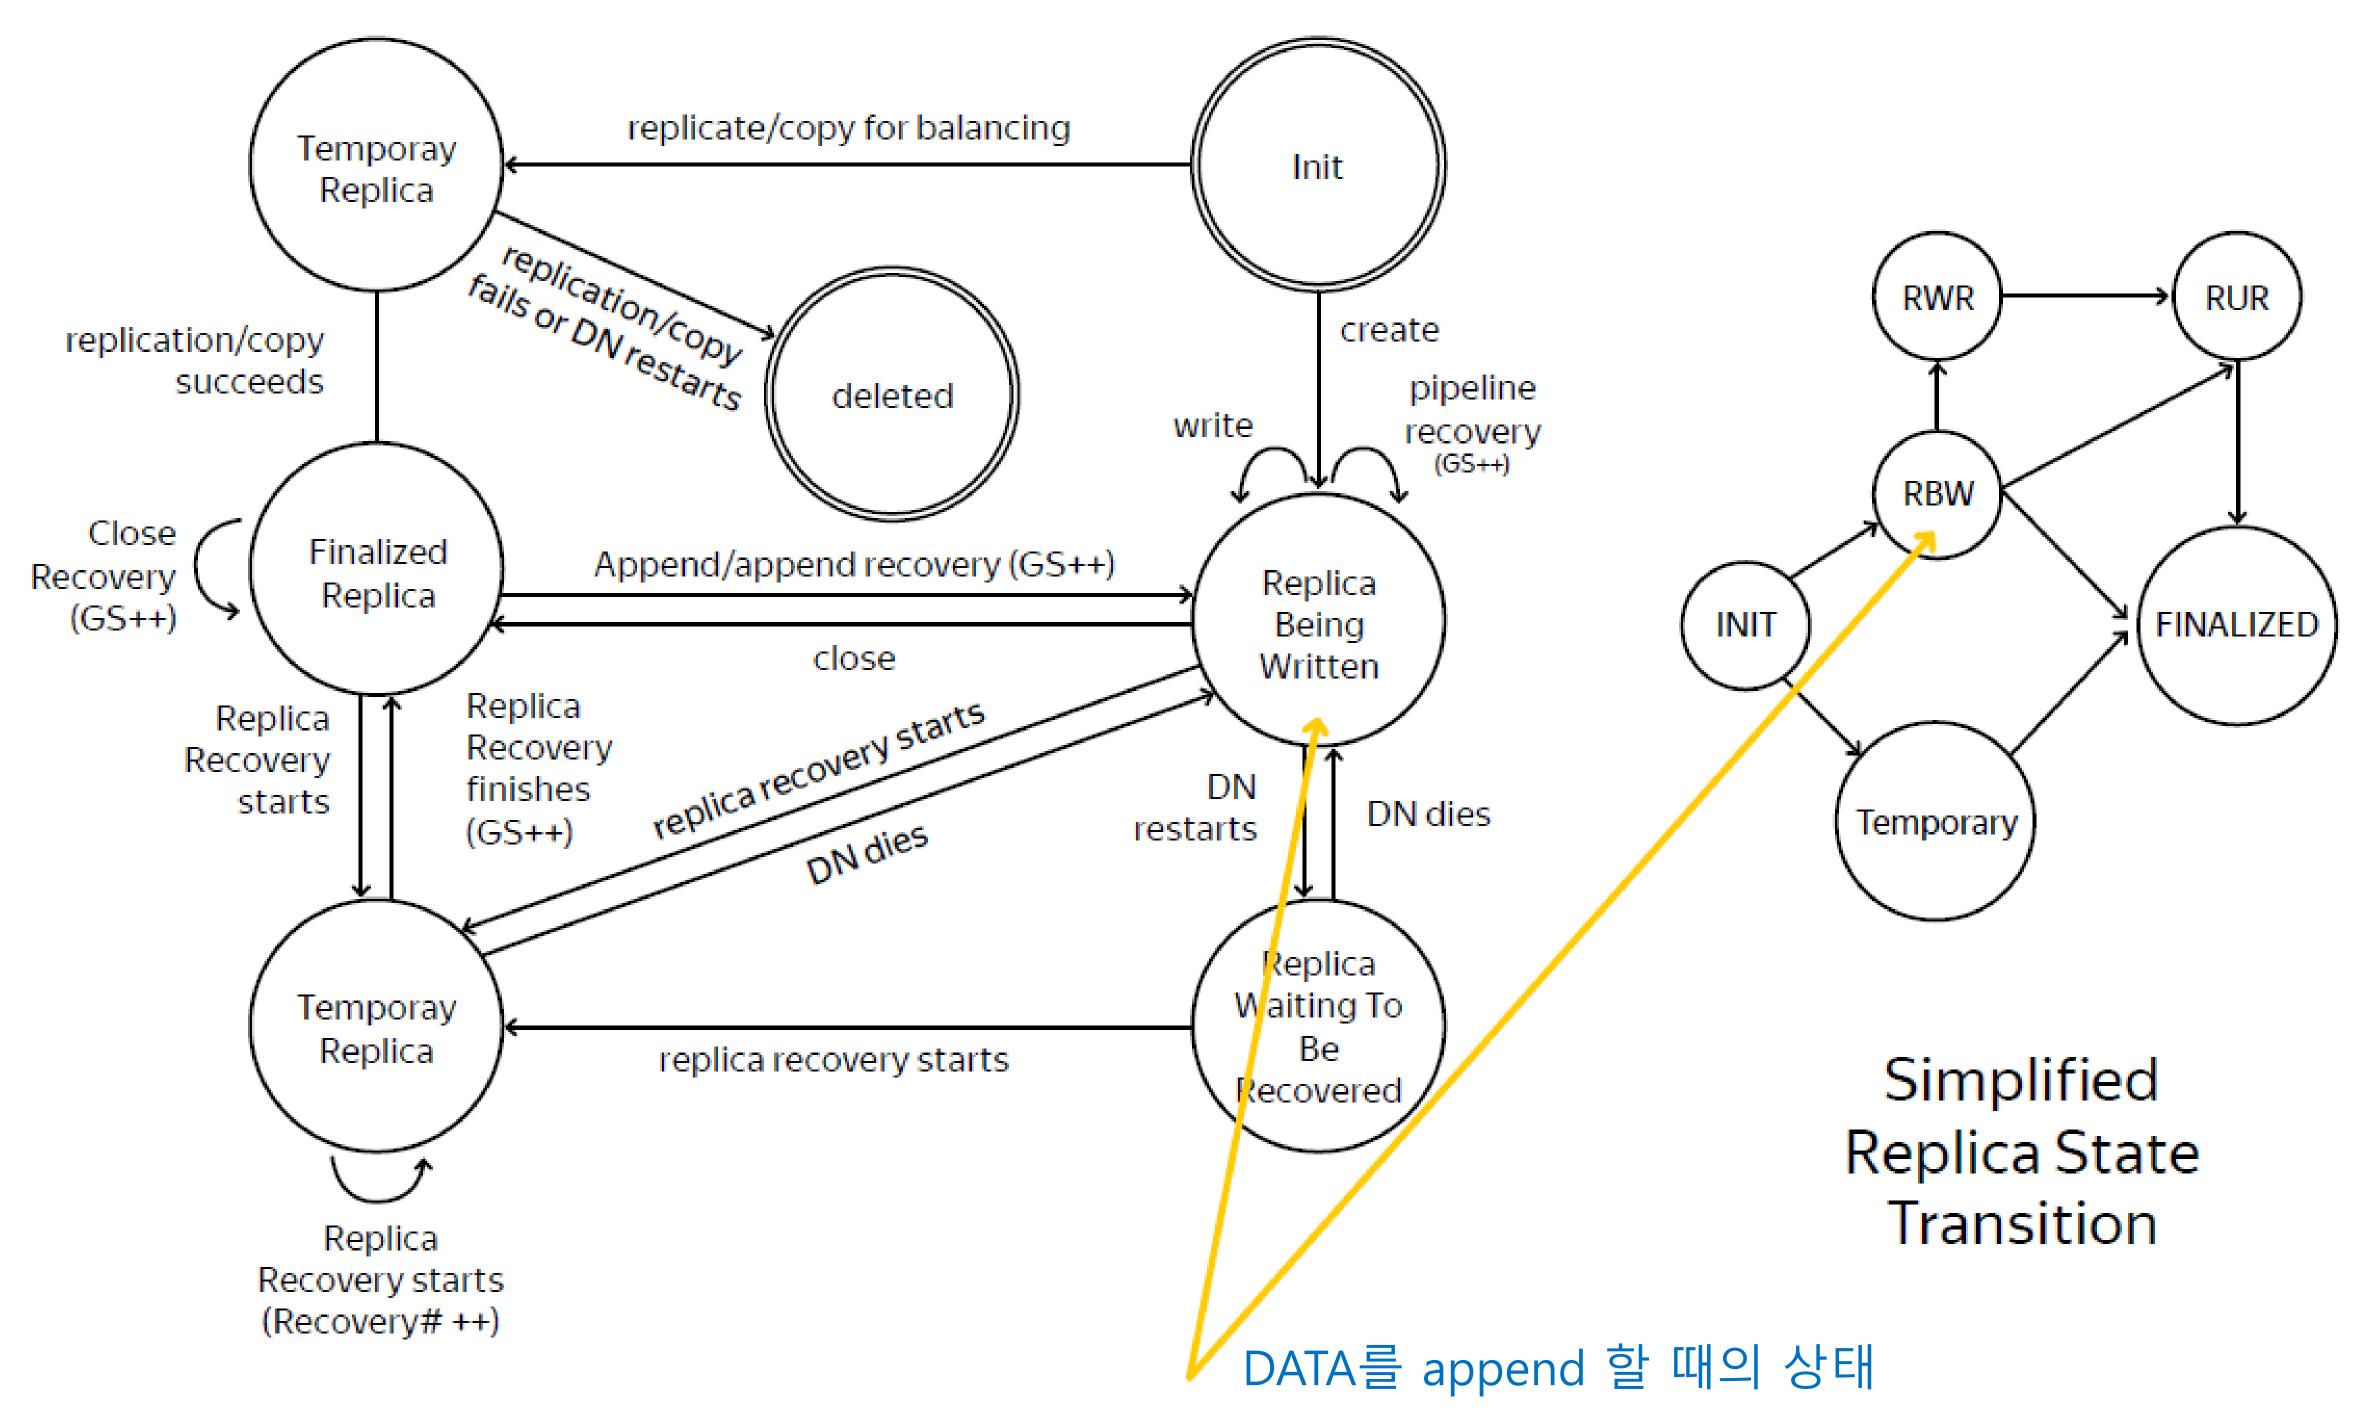


Finalized 완전한 상태 (read consistency를 유지한다.)

= frozen

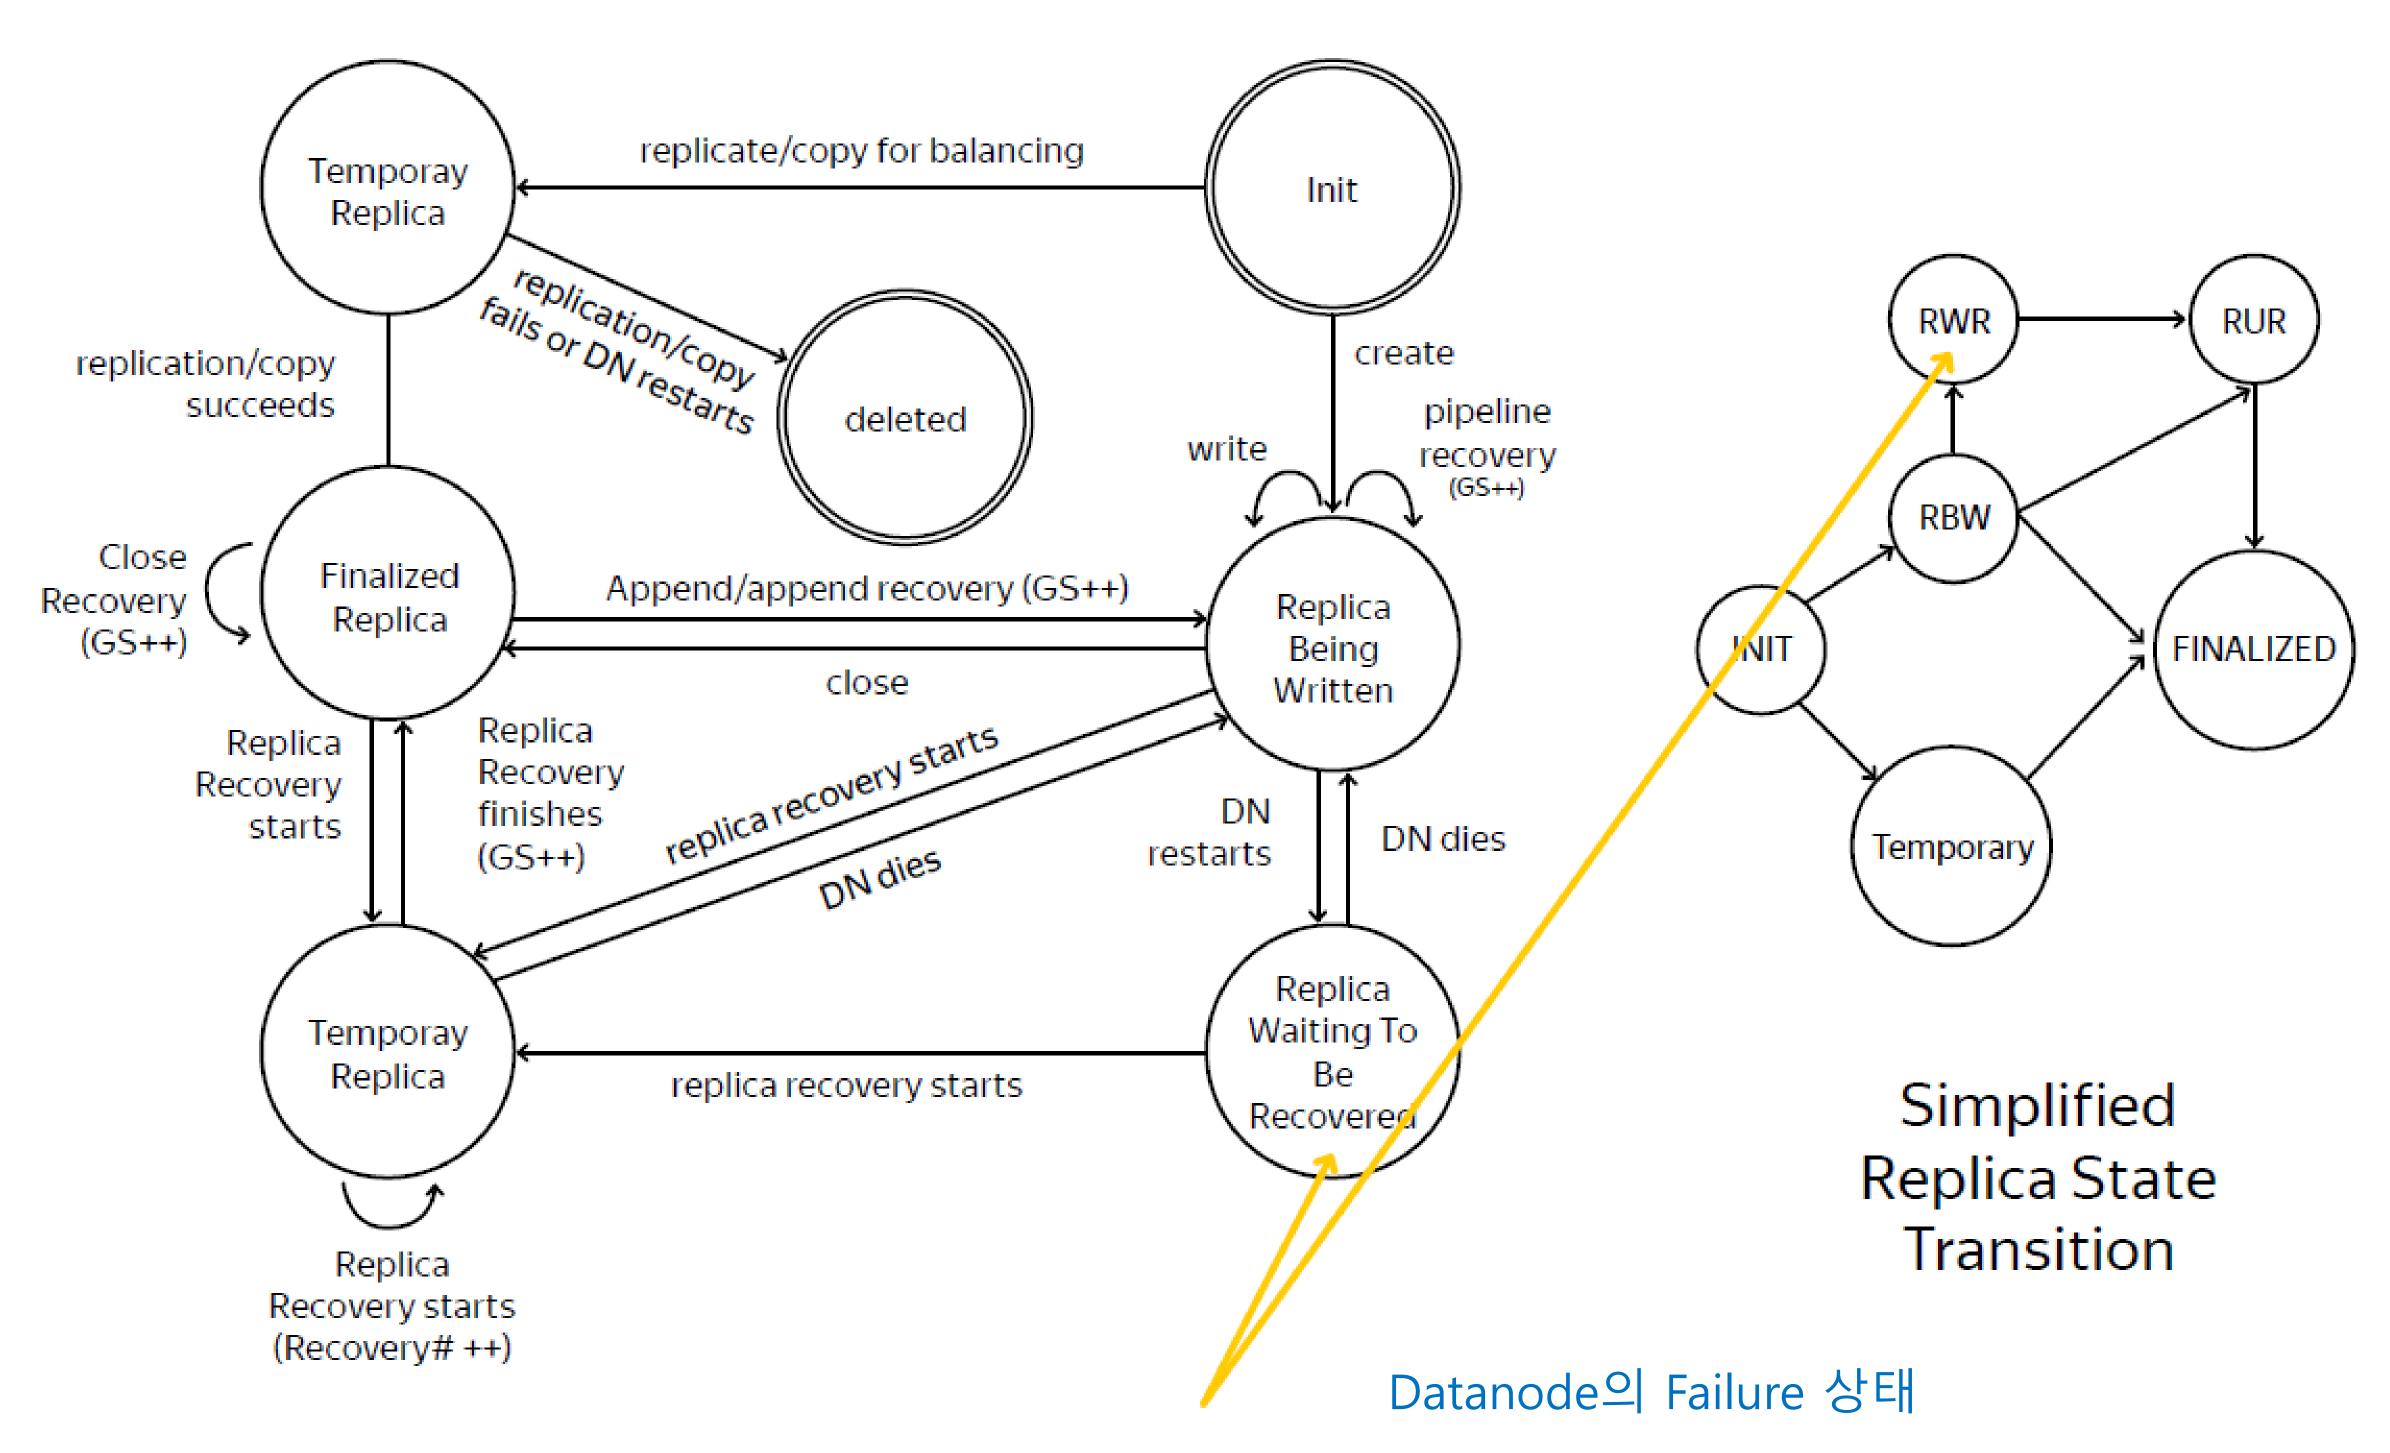
#### Finalized





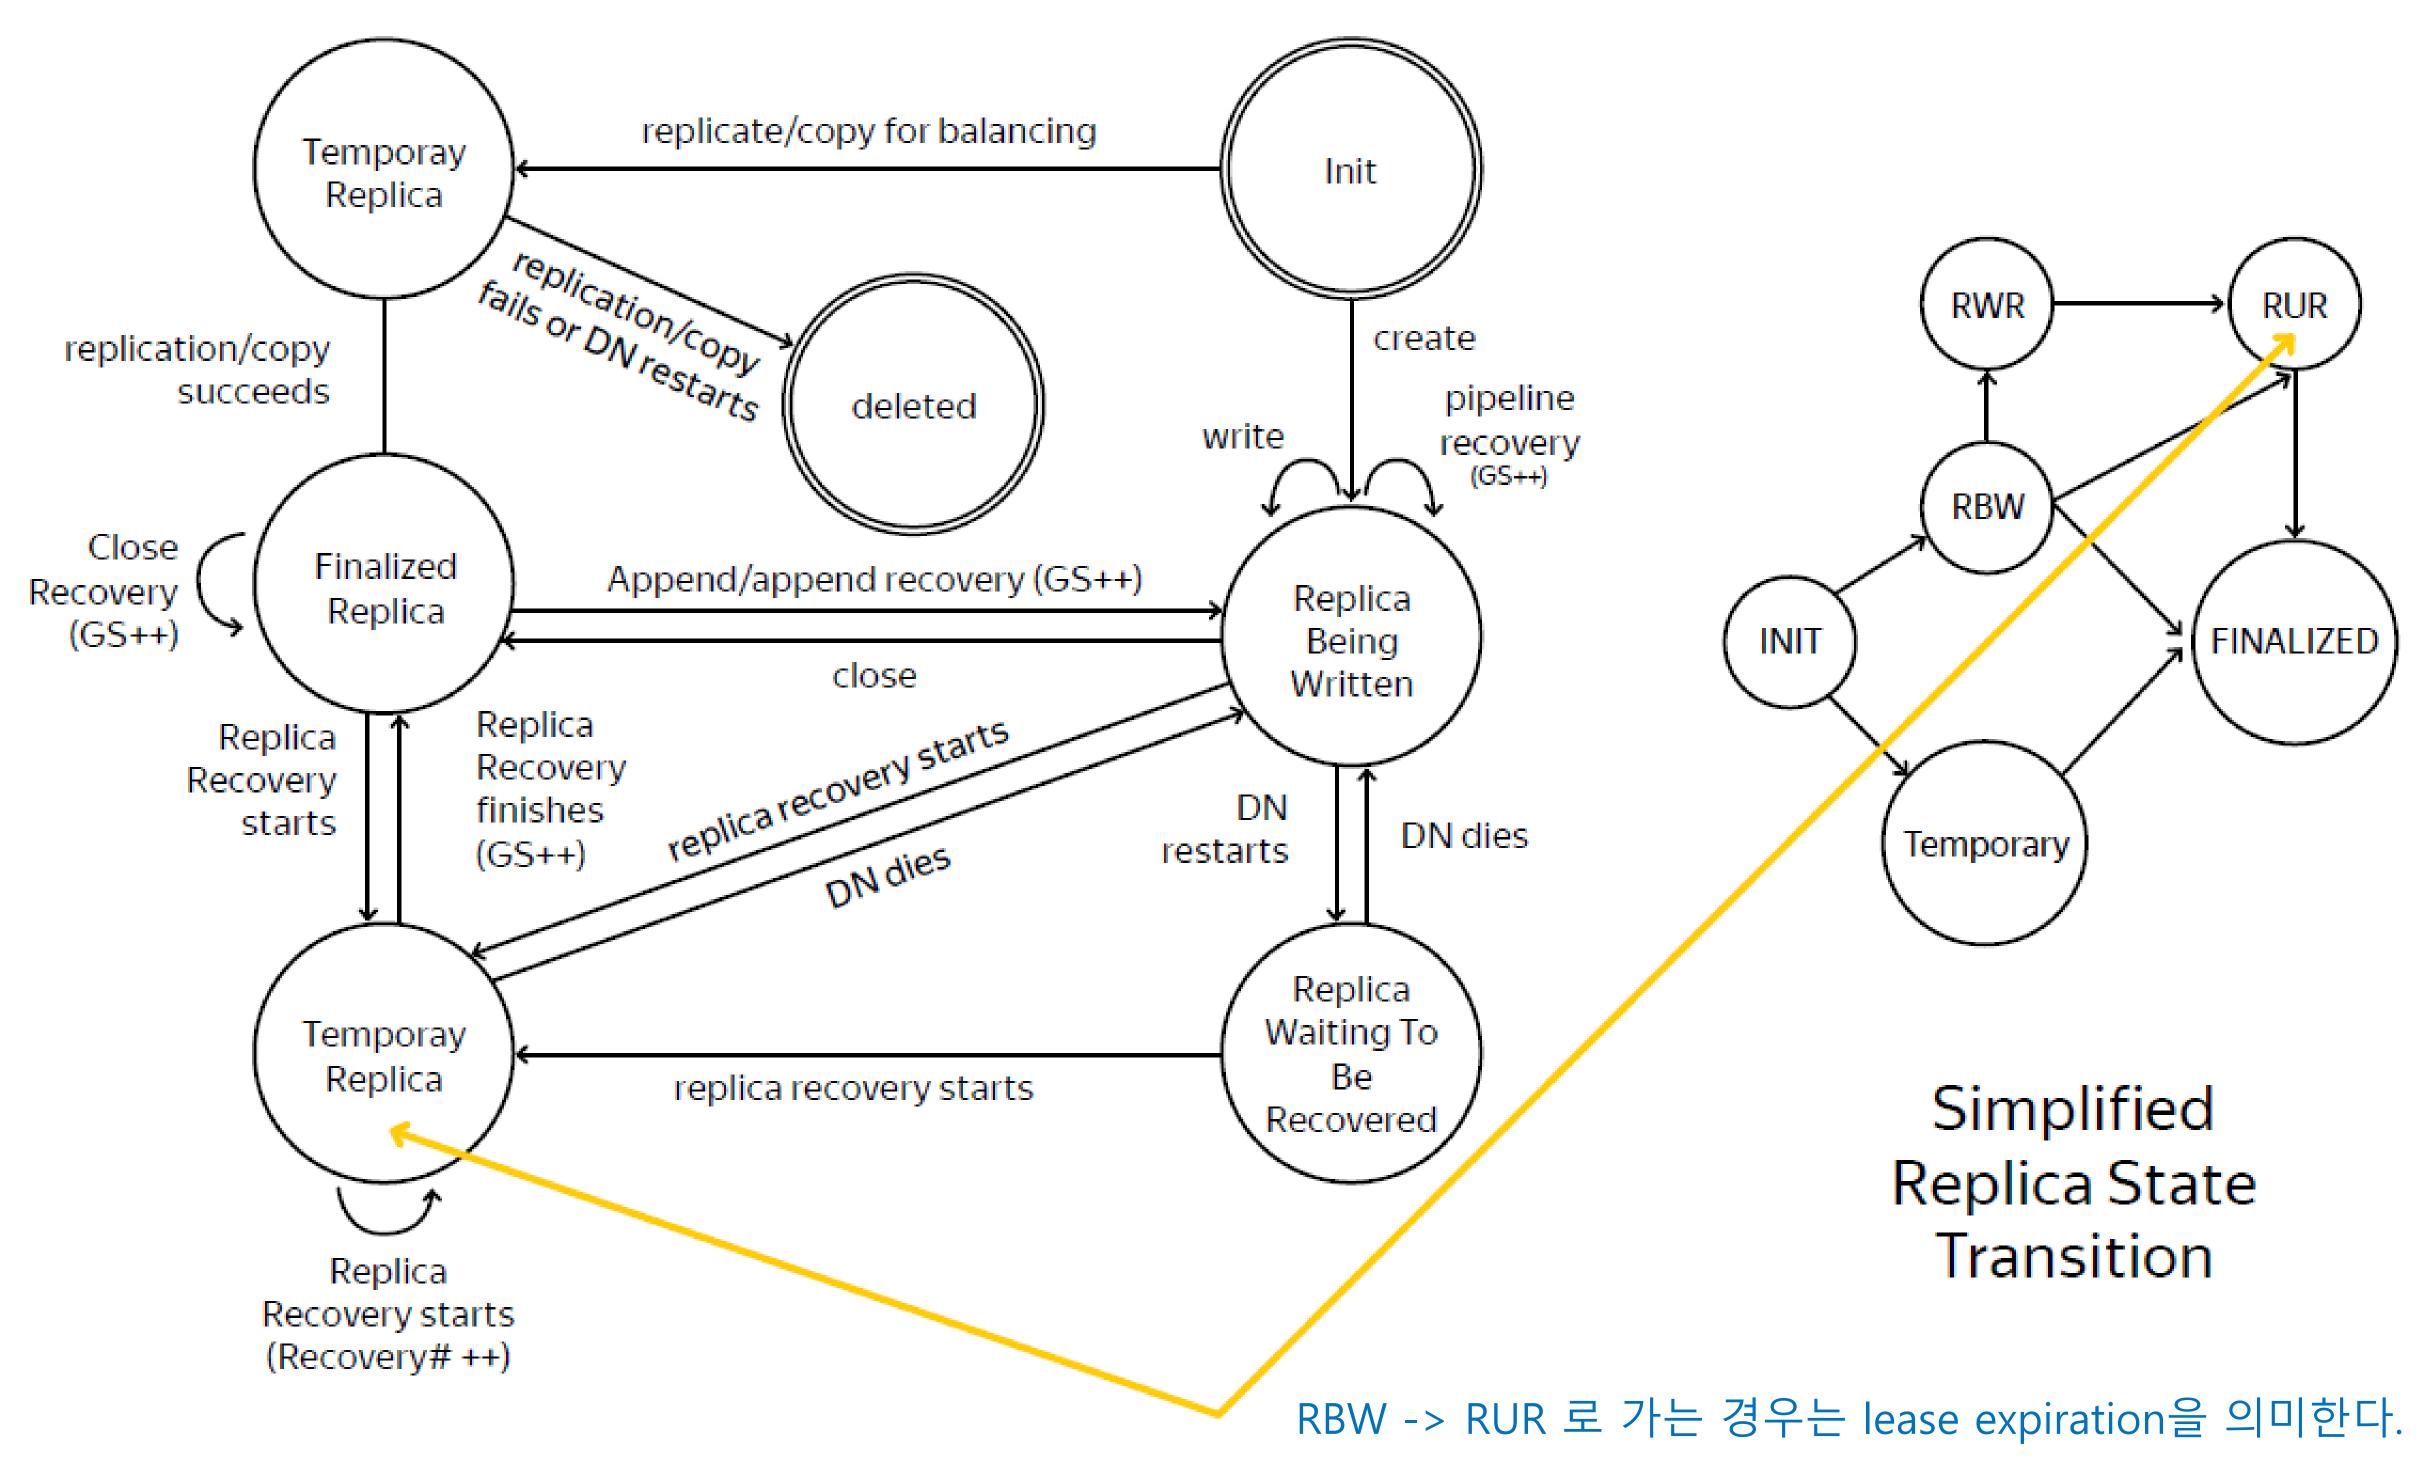
Replica Being Written to

RBW 상태에서는 namenode의 meta 정보와 다를 수 있음



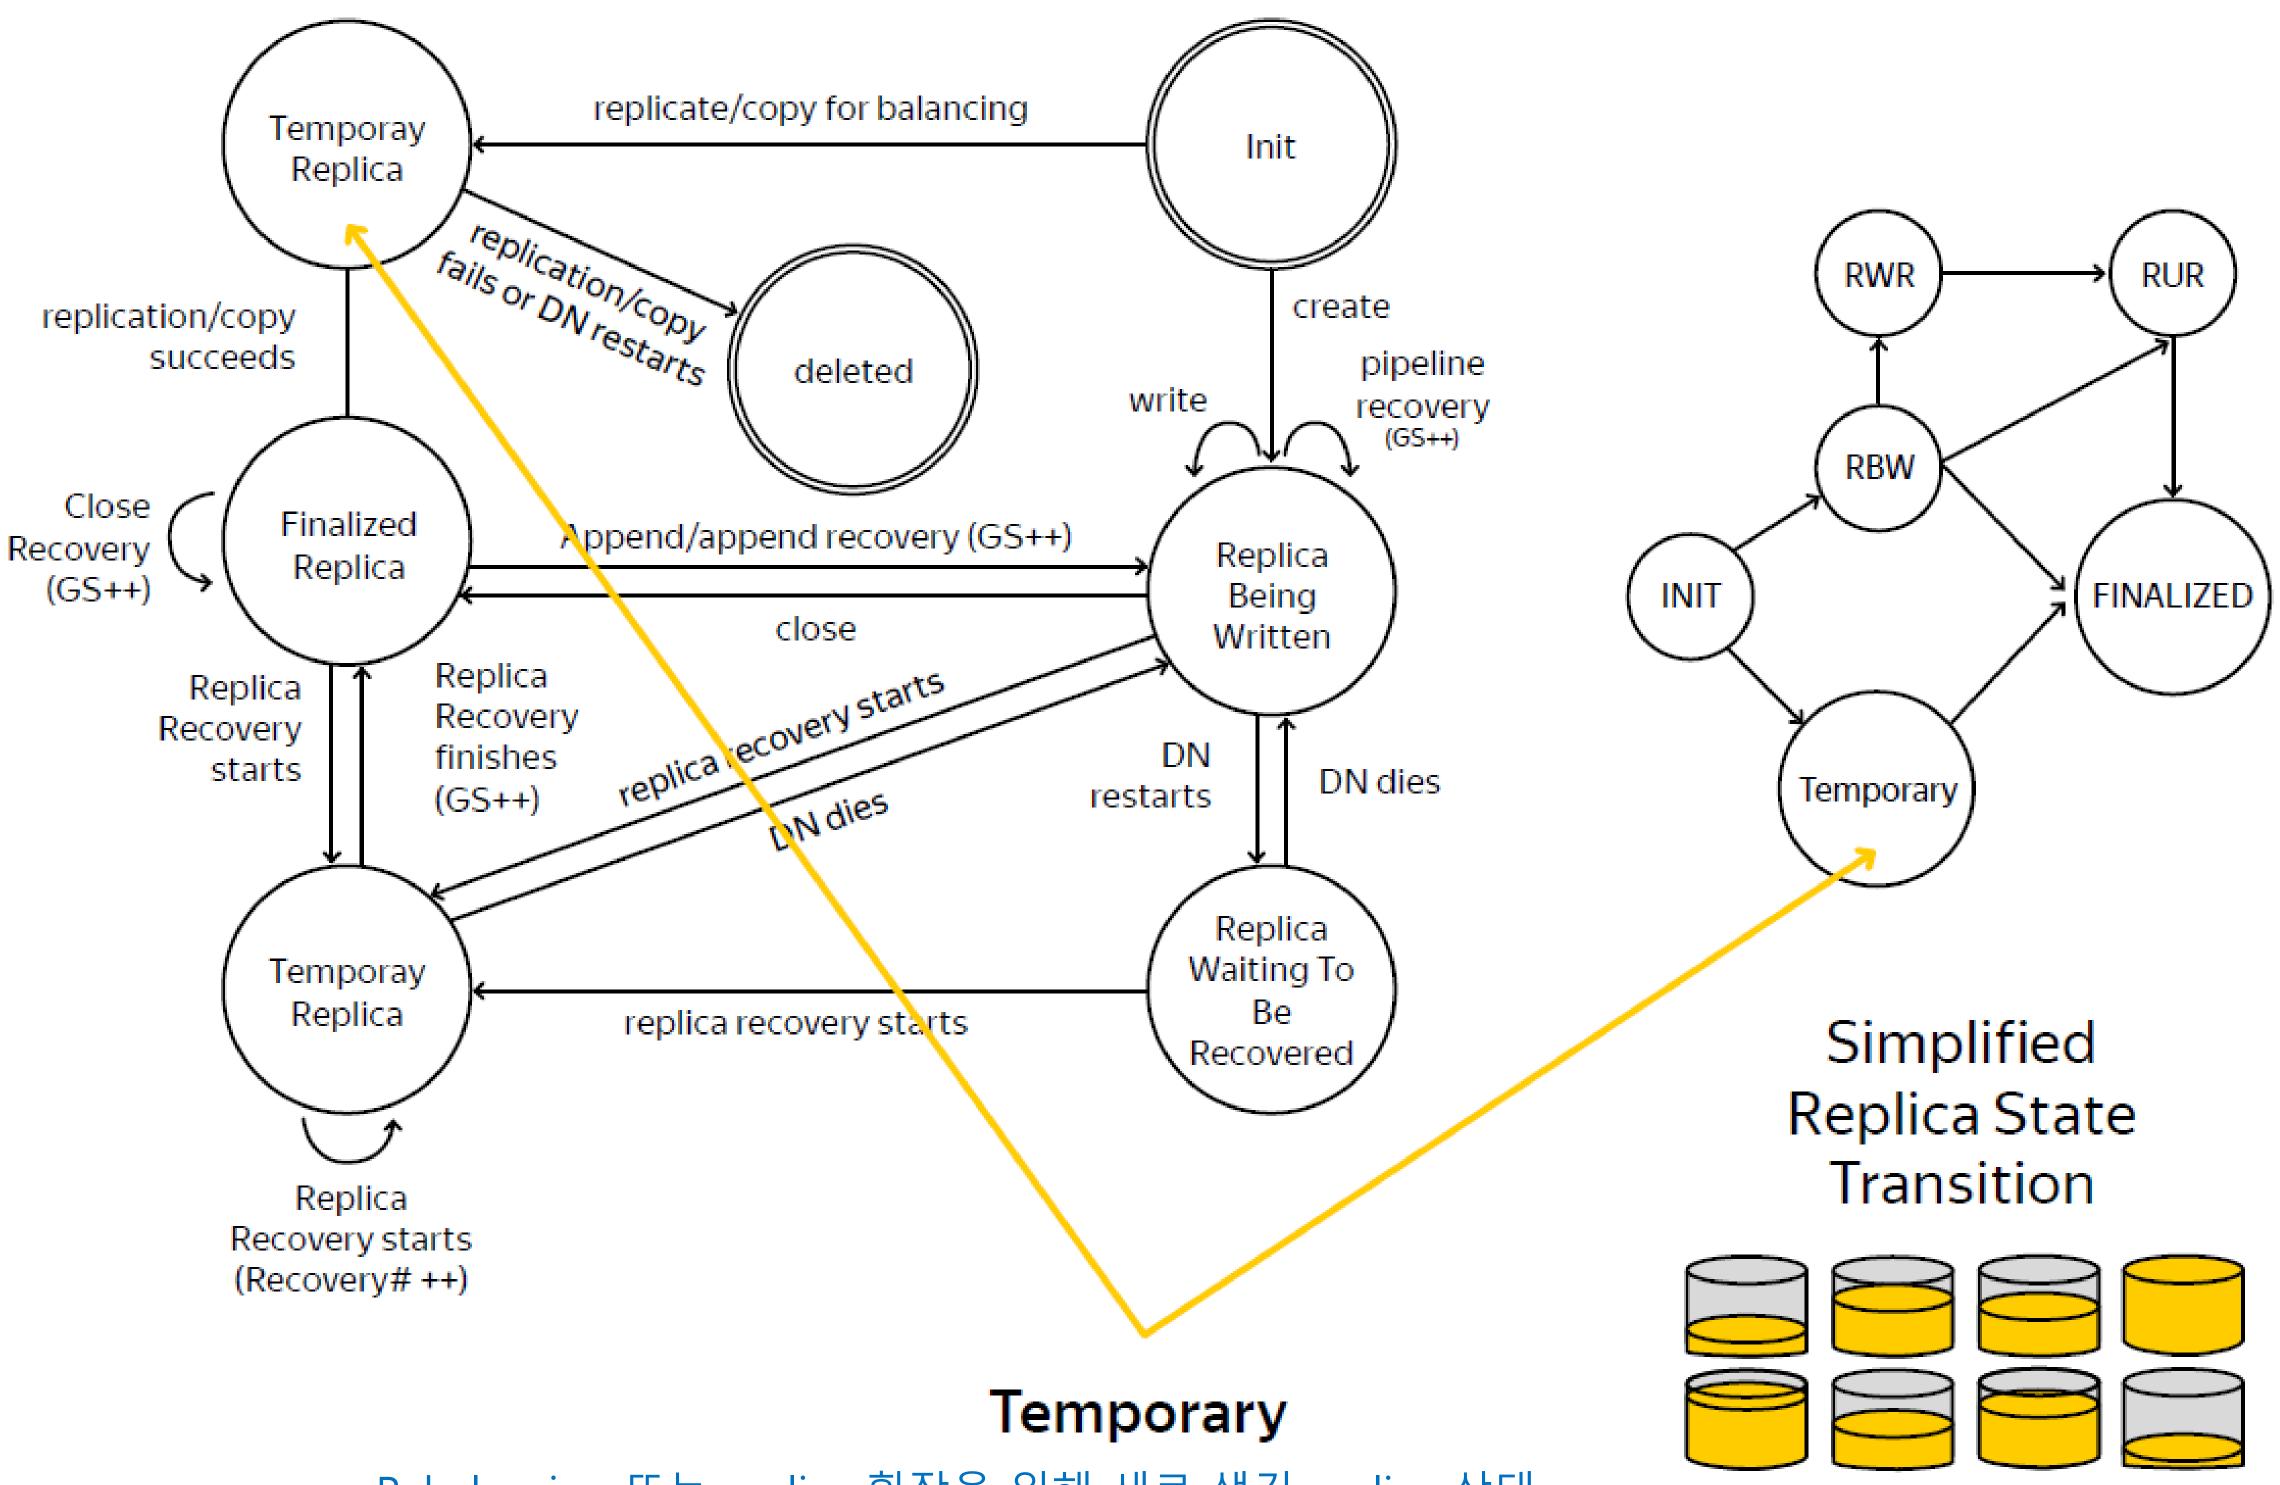
#### Replica Waiting to be Recovered

RWR 상태는 datanode 파이프라인에 연결되지 않는다. 이 replica는 버려지거나 특별한 recovery를 실행할 수 있다.



Replica Under Recovery

Lease : Client는 파일을 write하는 독점 권한 (exclusive access) 을 요청한다. 단, read에는 독점 권한이 없음 Lease expiration : write하기 위한 접근 중 에러 발생(주로 site failure로 인한 문제)

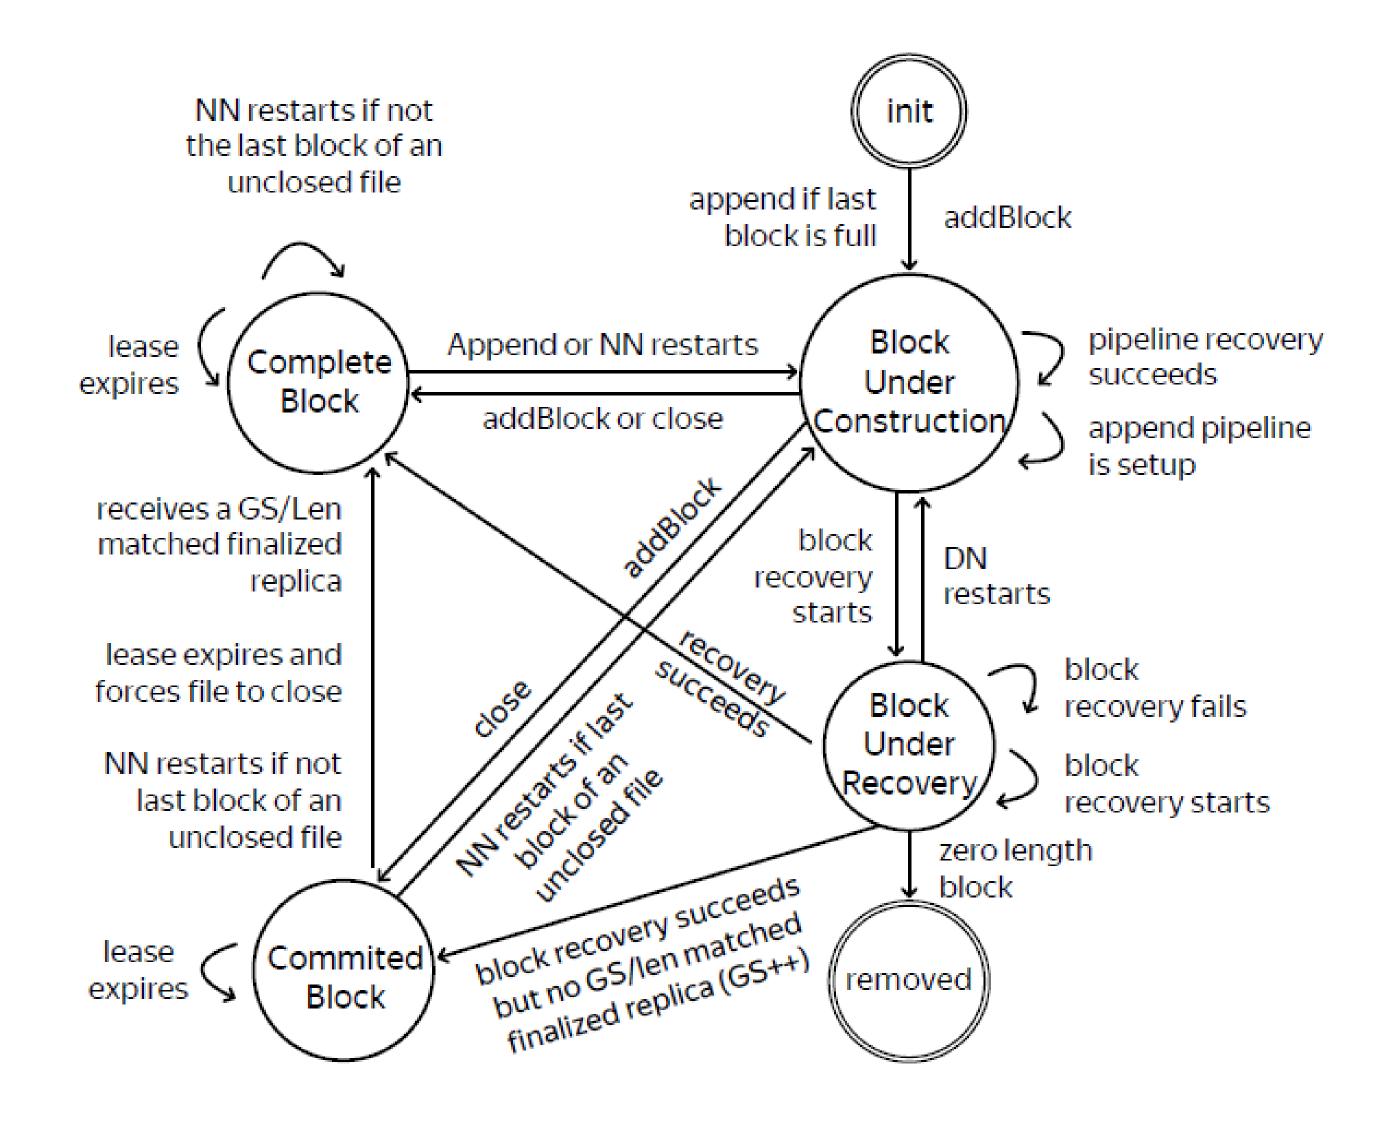


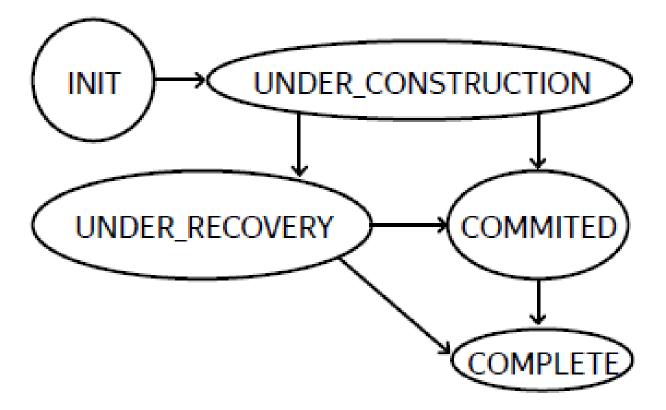
Rebalancing 또는 replica 확장을 위해 새로 생긴 replica 상태

데이터가 user에게 보이지 않는 점만 빼고는 RBW 상태와 같다. (finalized가 되어야 보인다.)

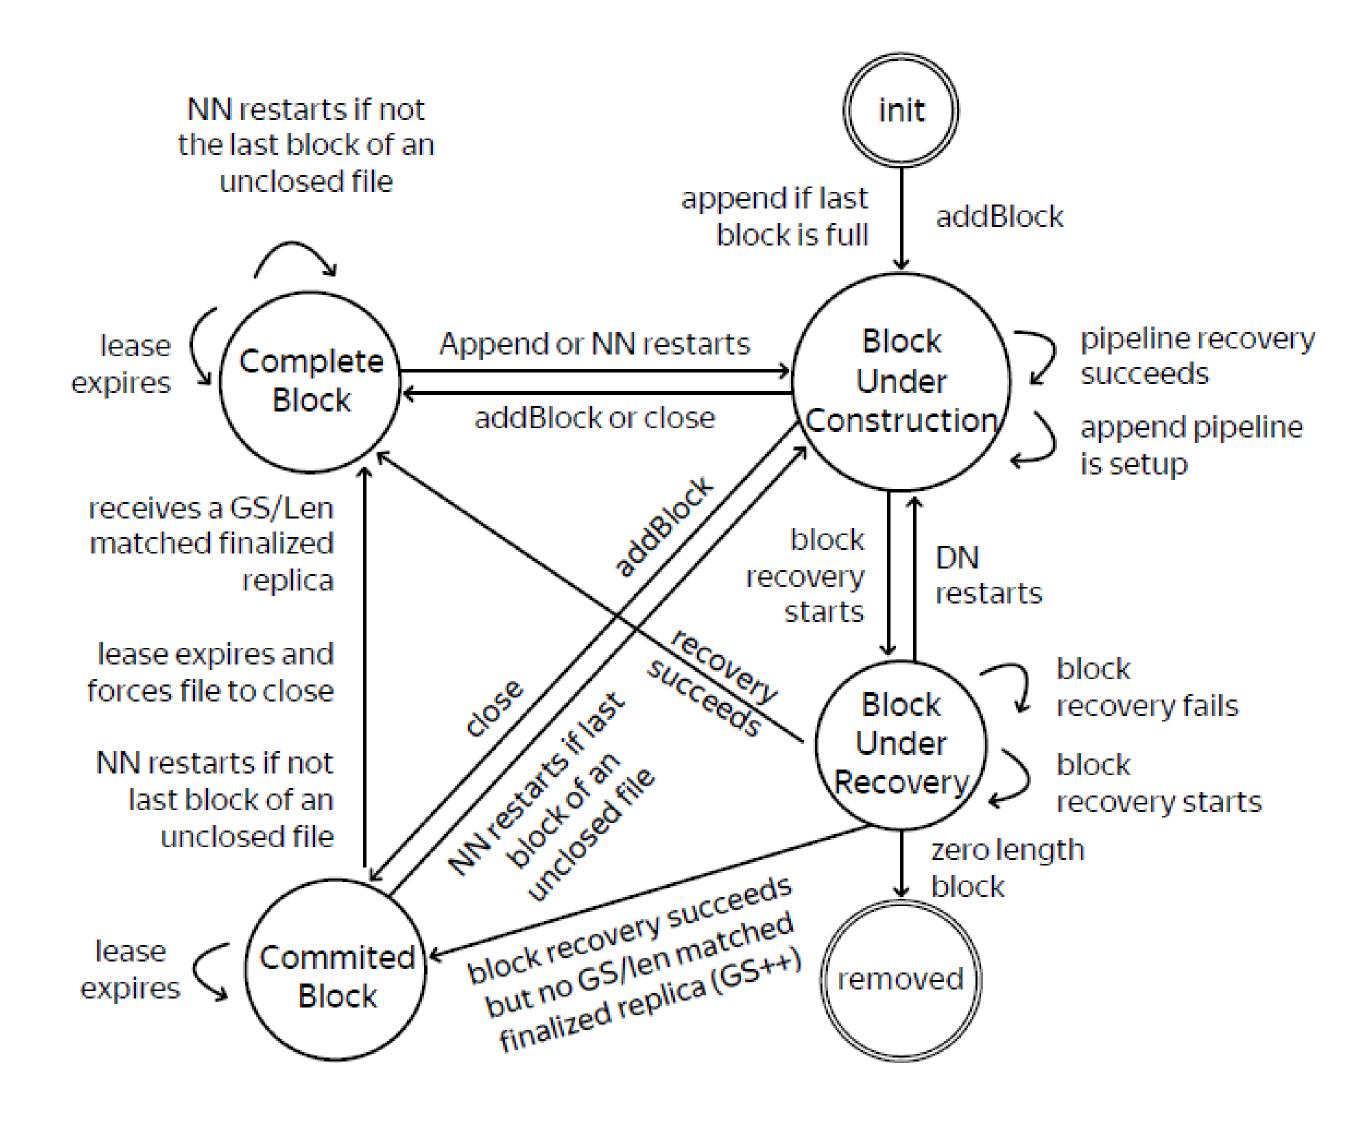
Rebalancing : 데이터가 cluster에 공평하게 분산된다는 보장을 하지 않기 때문에 하는 작업

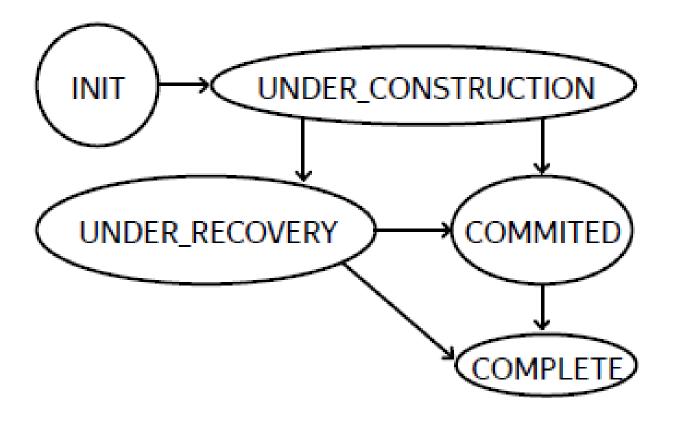
#### Namenode Block State





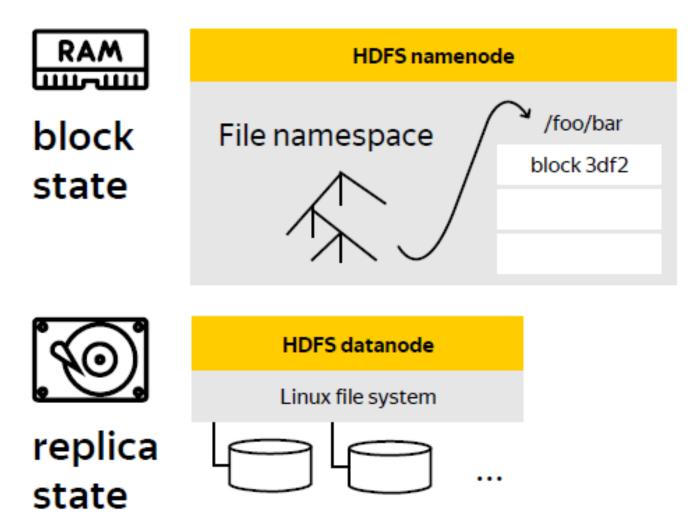
Simplified Block State Transition

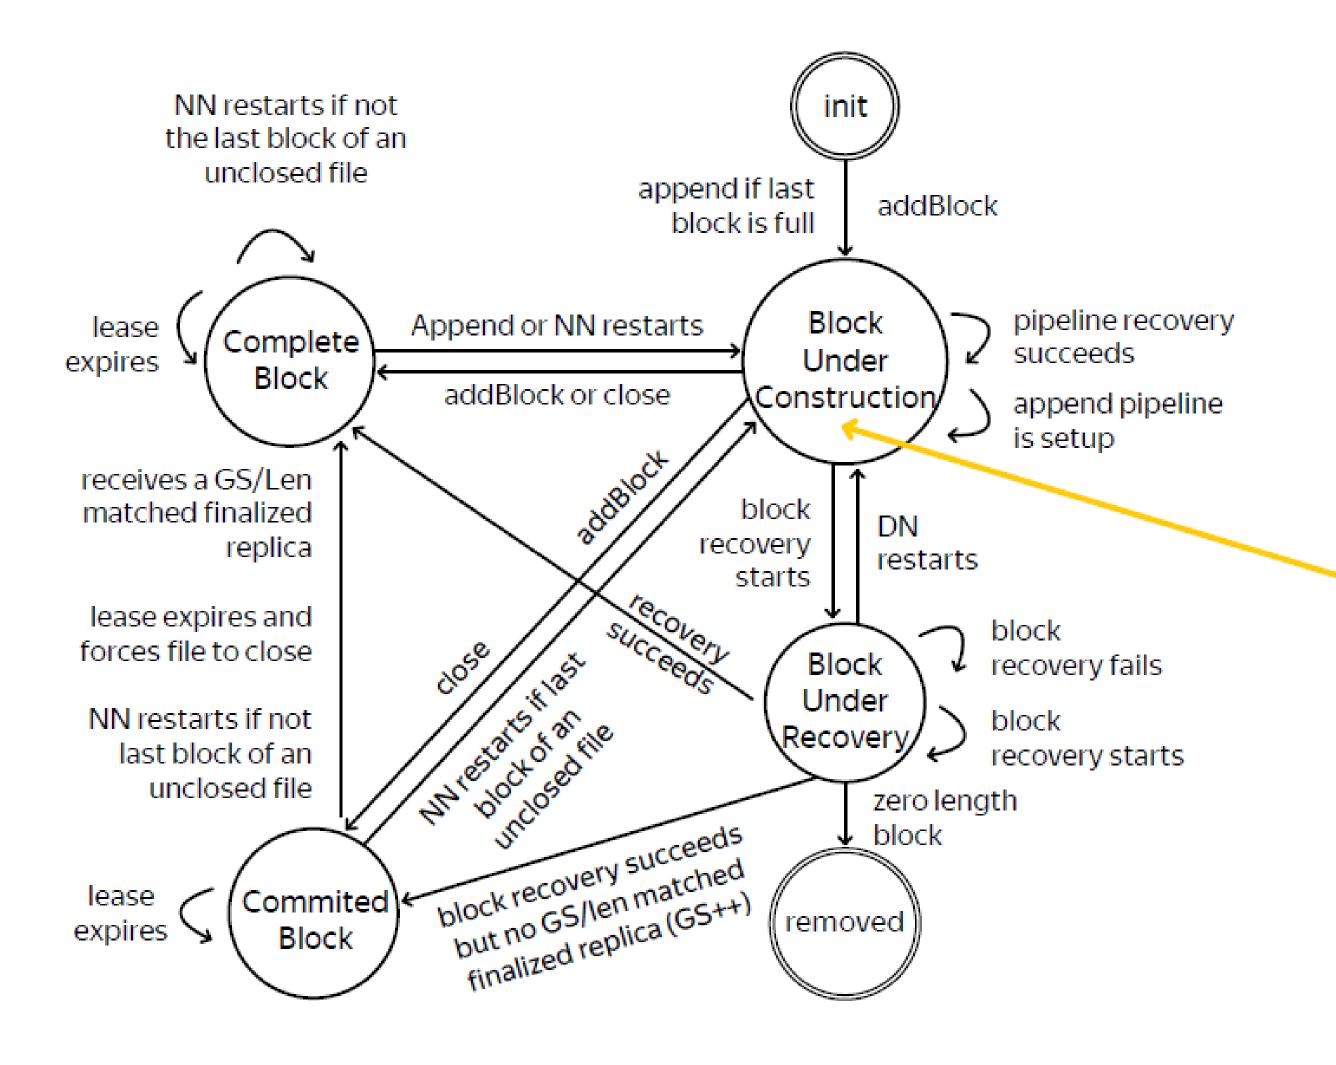




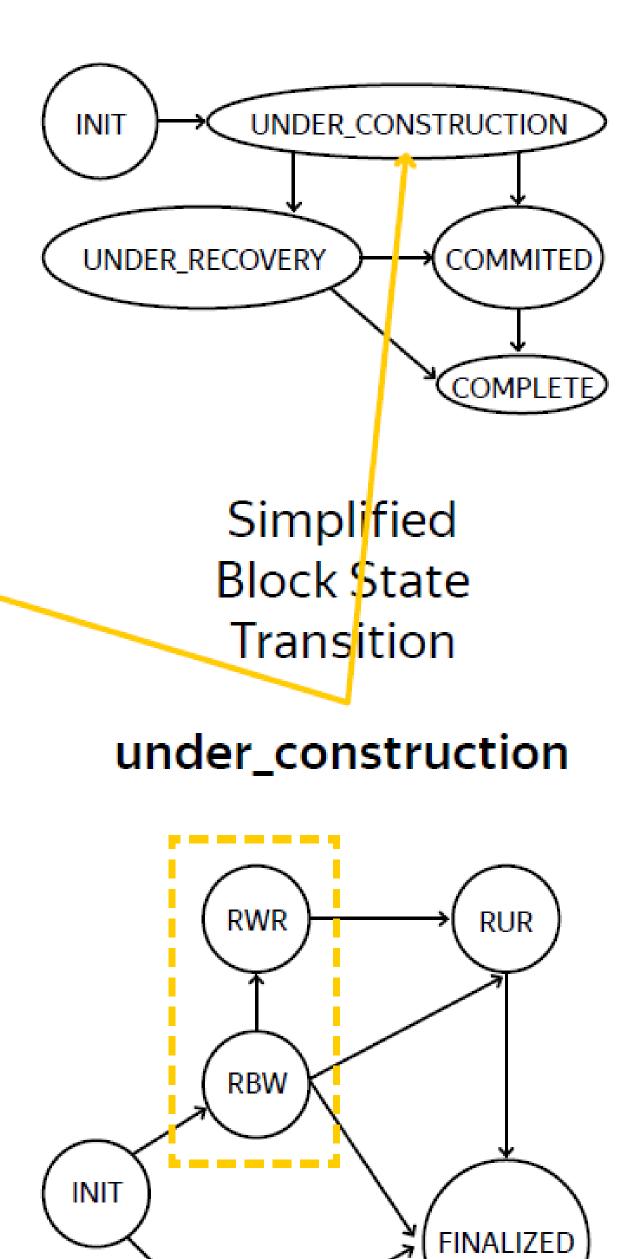
Simplified Block State Transition

Block state는 메모리에, Replica state는 disk에 저장된다.

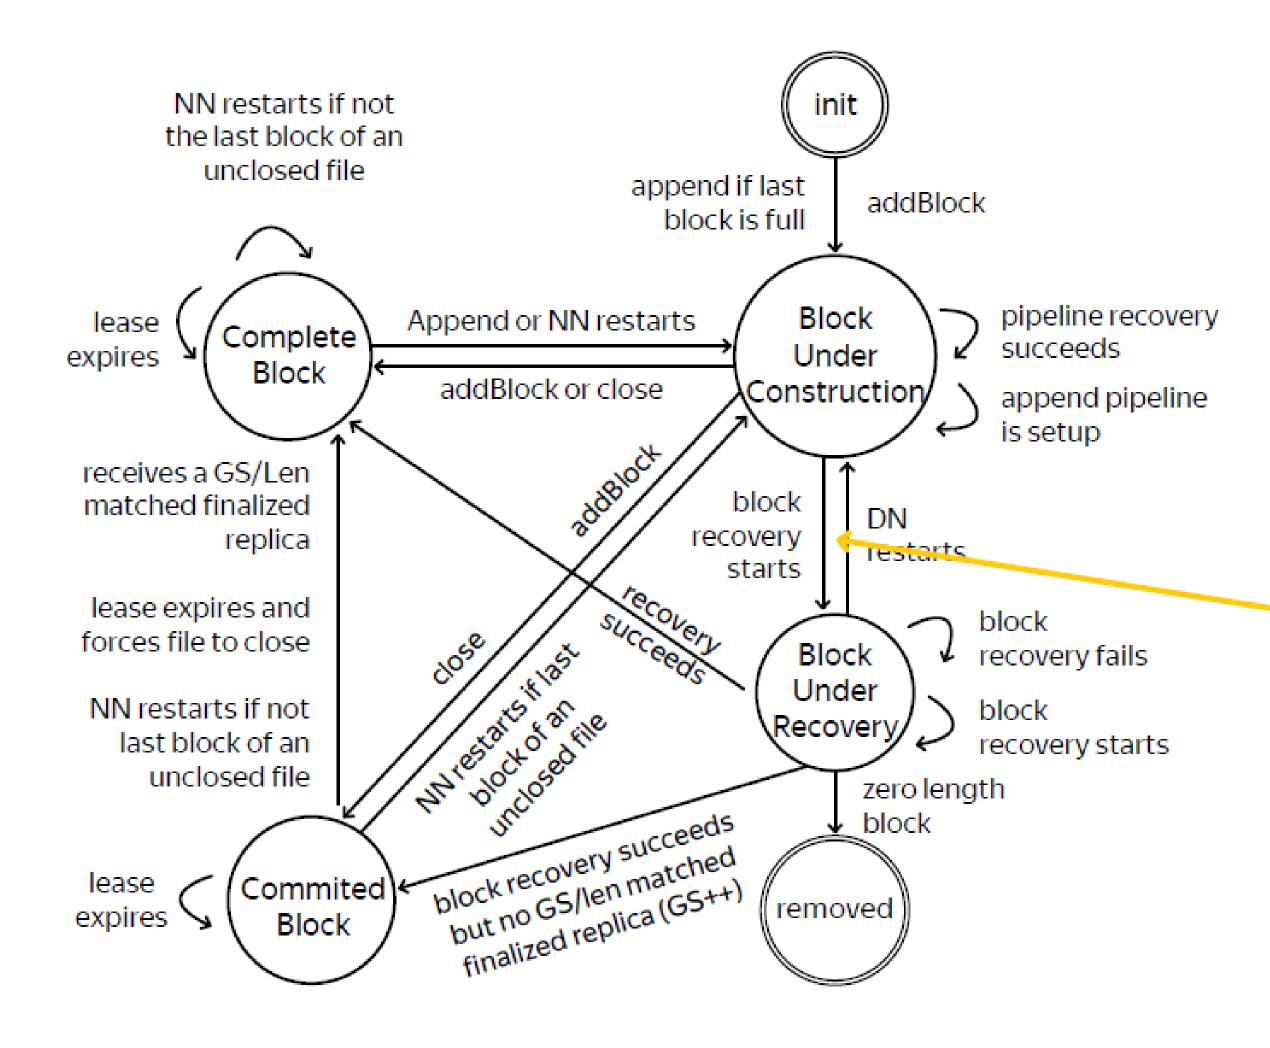




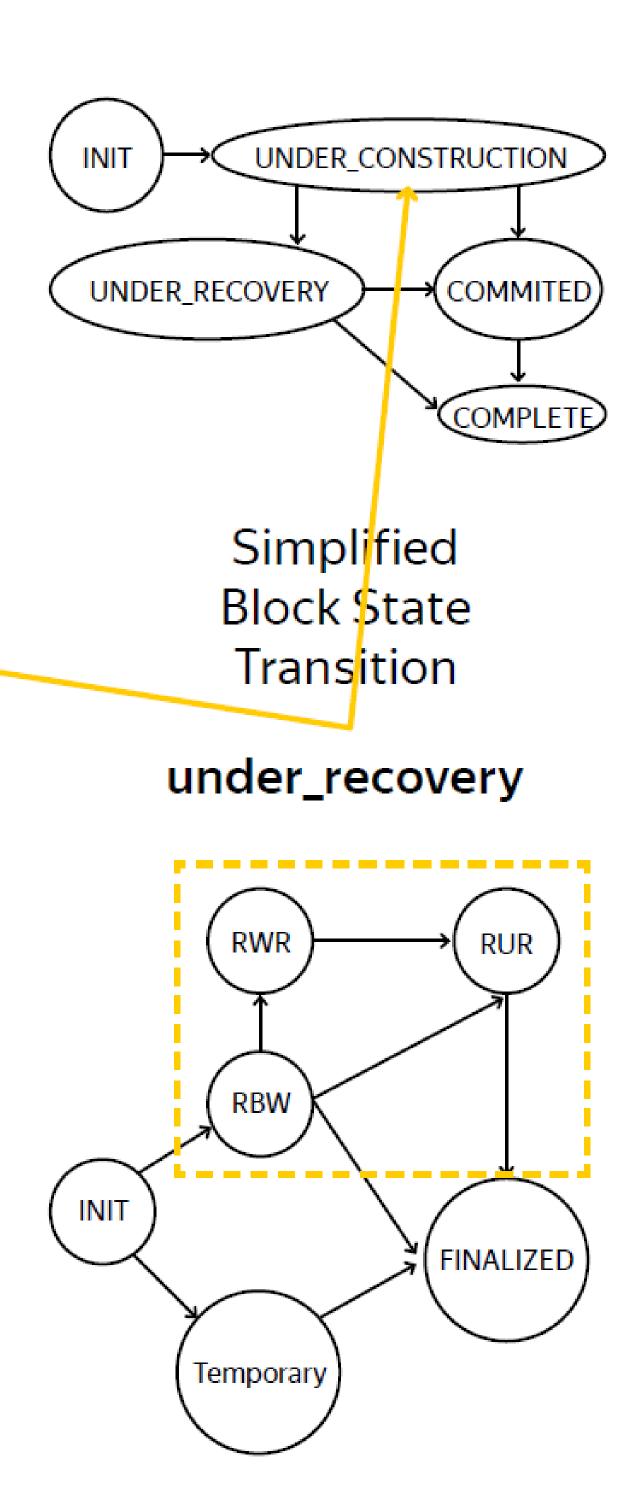
Under\_construction 상태는 RBW와 RWR 상태를 포함한다.

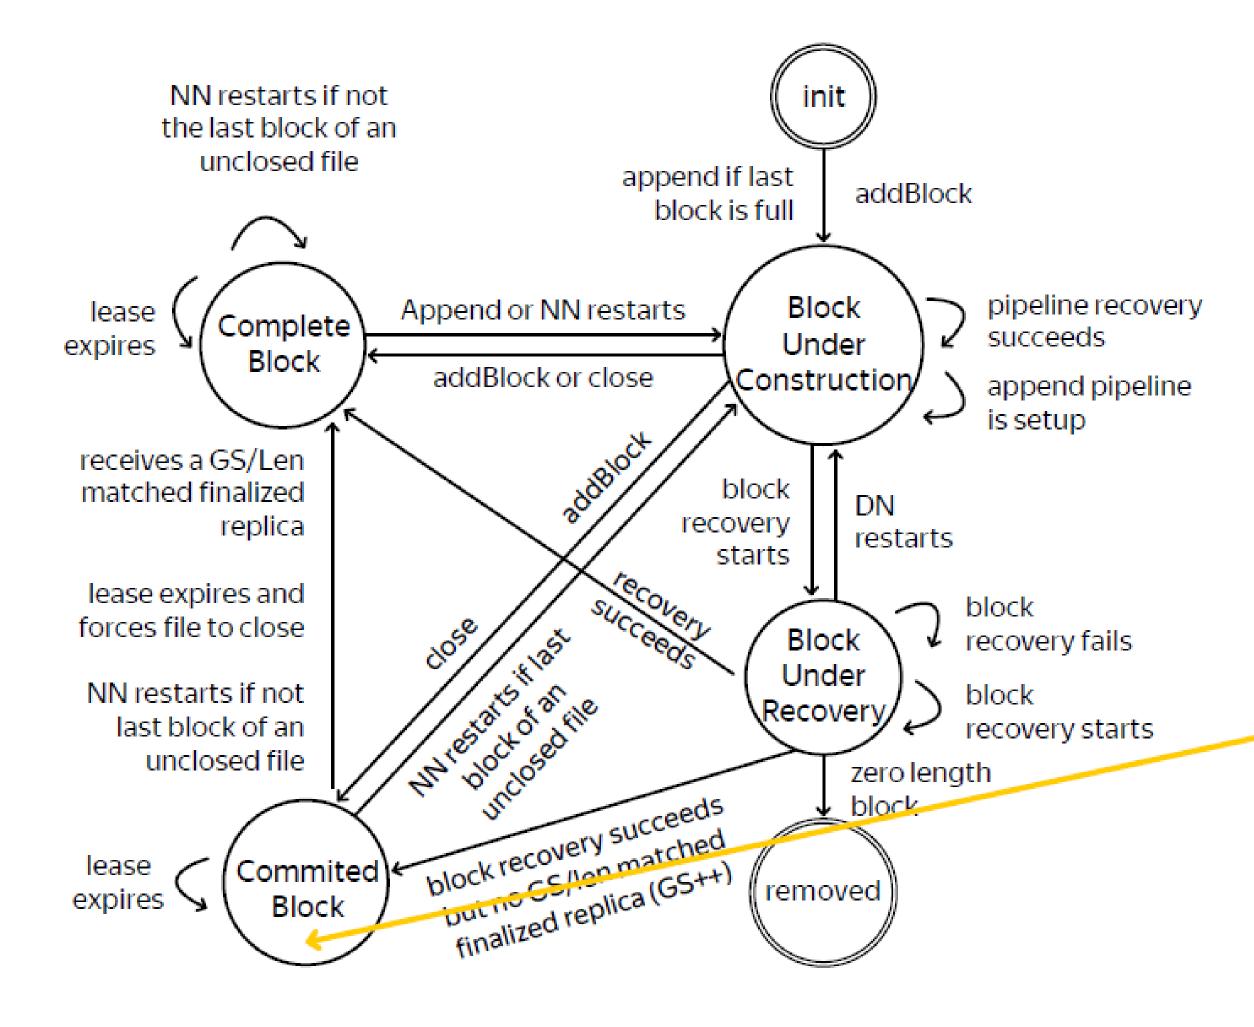


Temporary

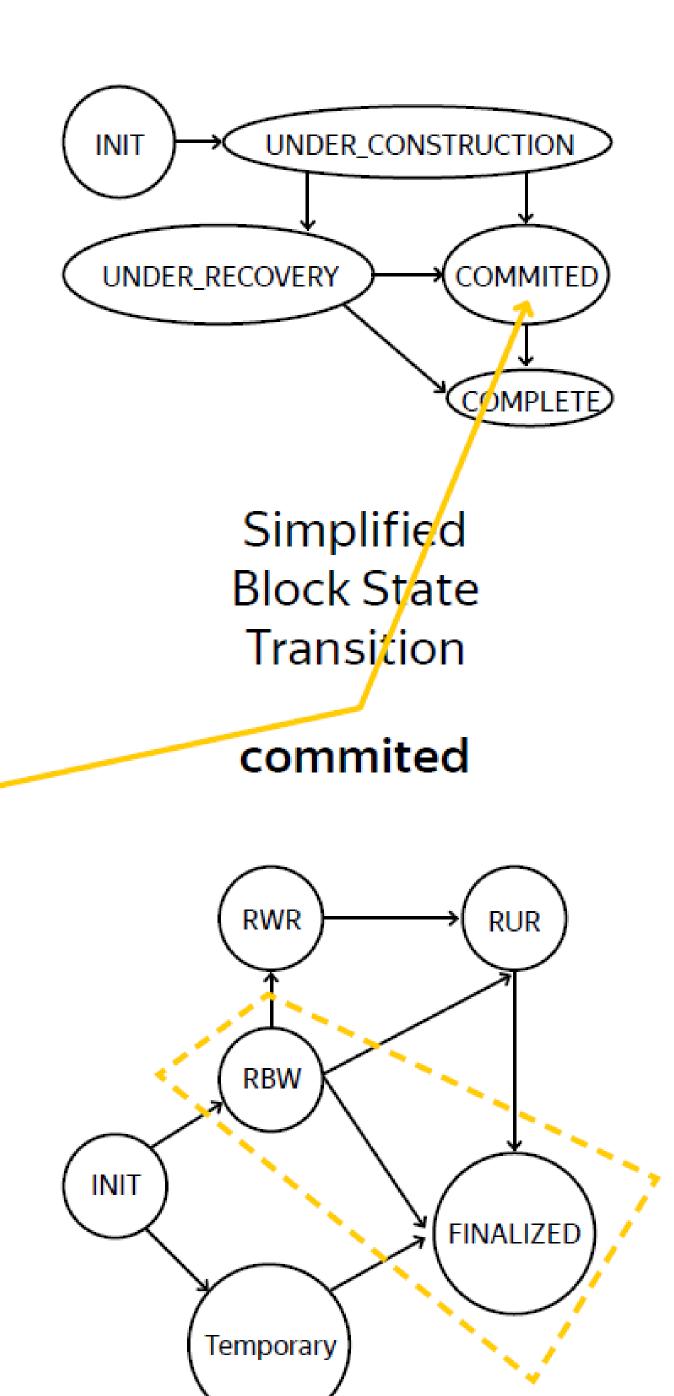


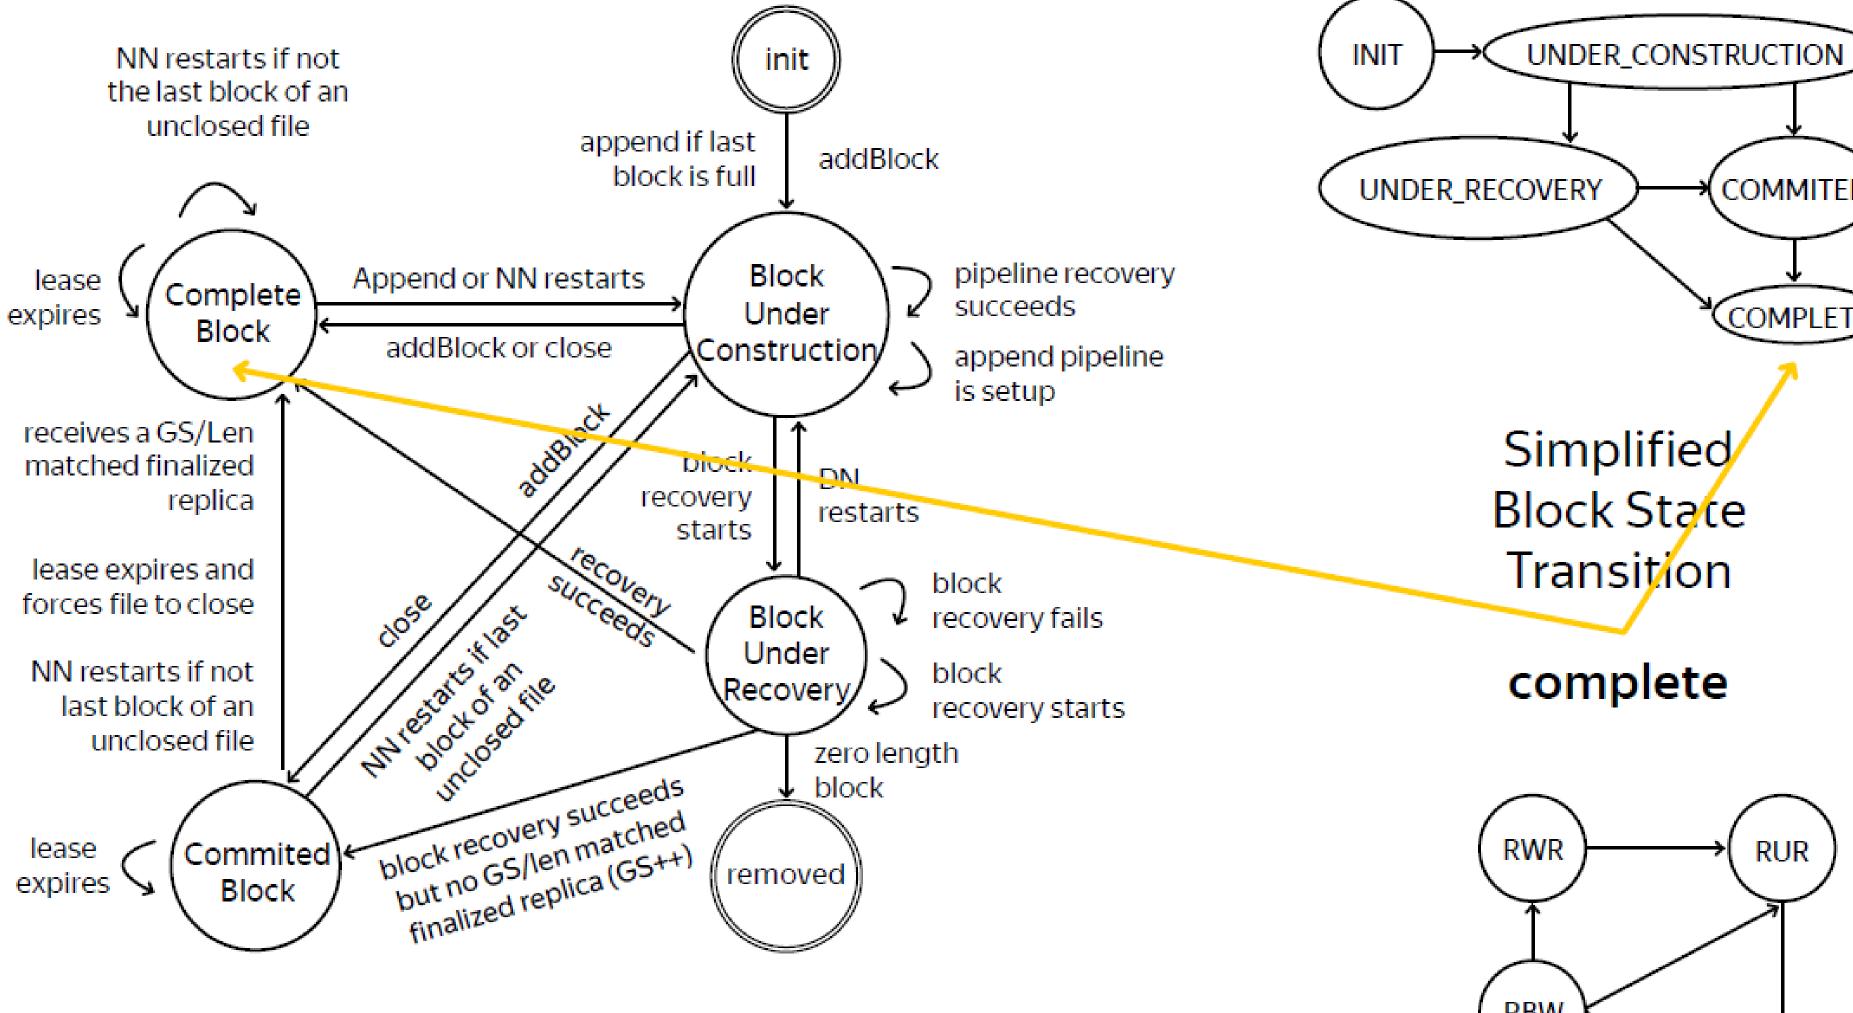
Replica가 RUR 상태가 될 때 under\_recovery로 전환된다.



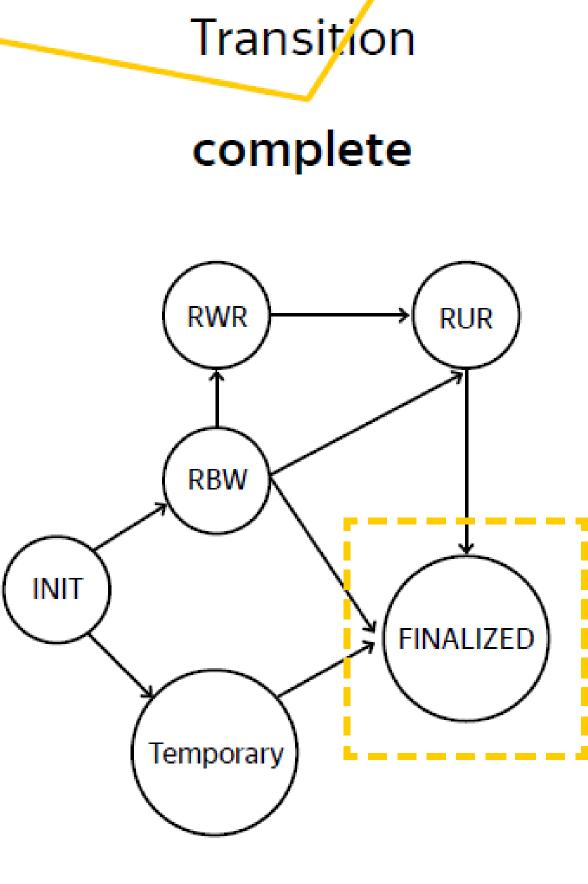


Committed 상태는 일부 replica가 finalized 상태가 되었다는 의미 남은 RBW들을 finalized 될 때까지 track한다.





모든 replica가 finalized 상태임을 의미한다.



COMMITED

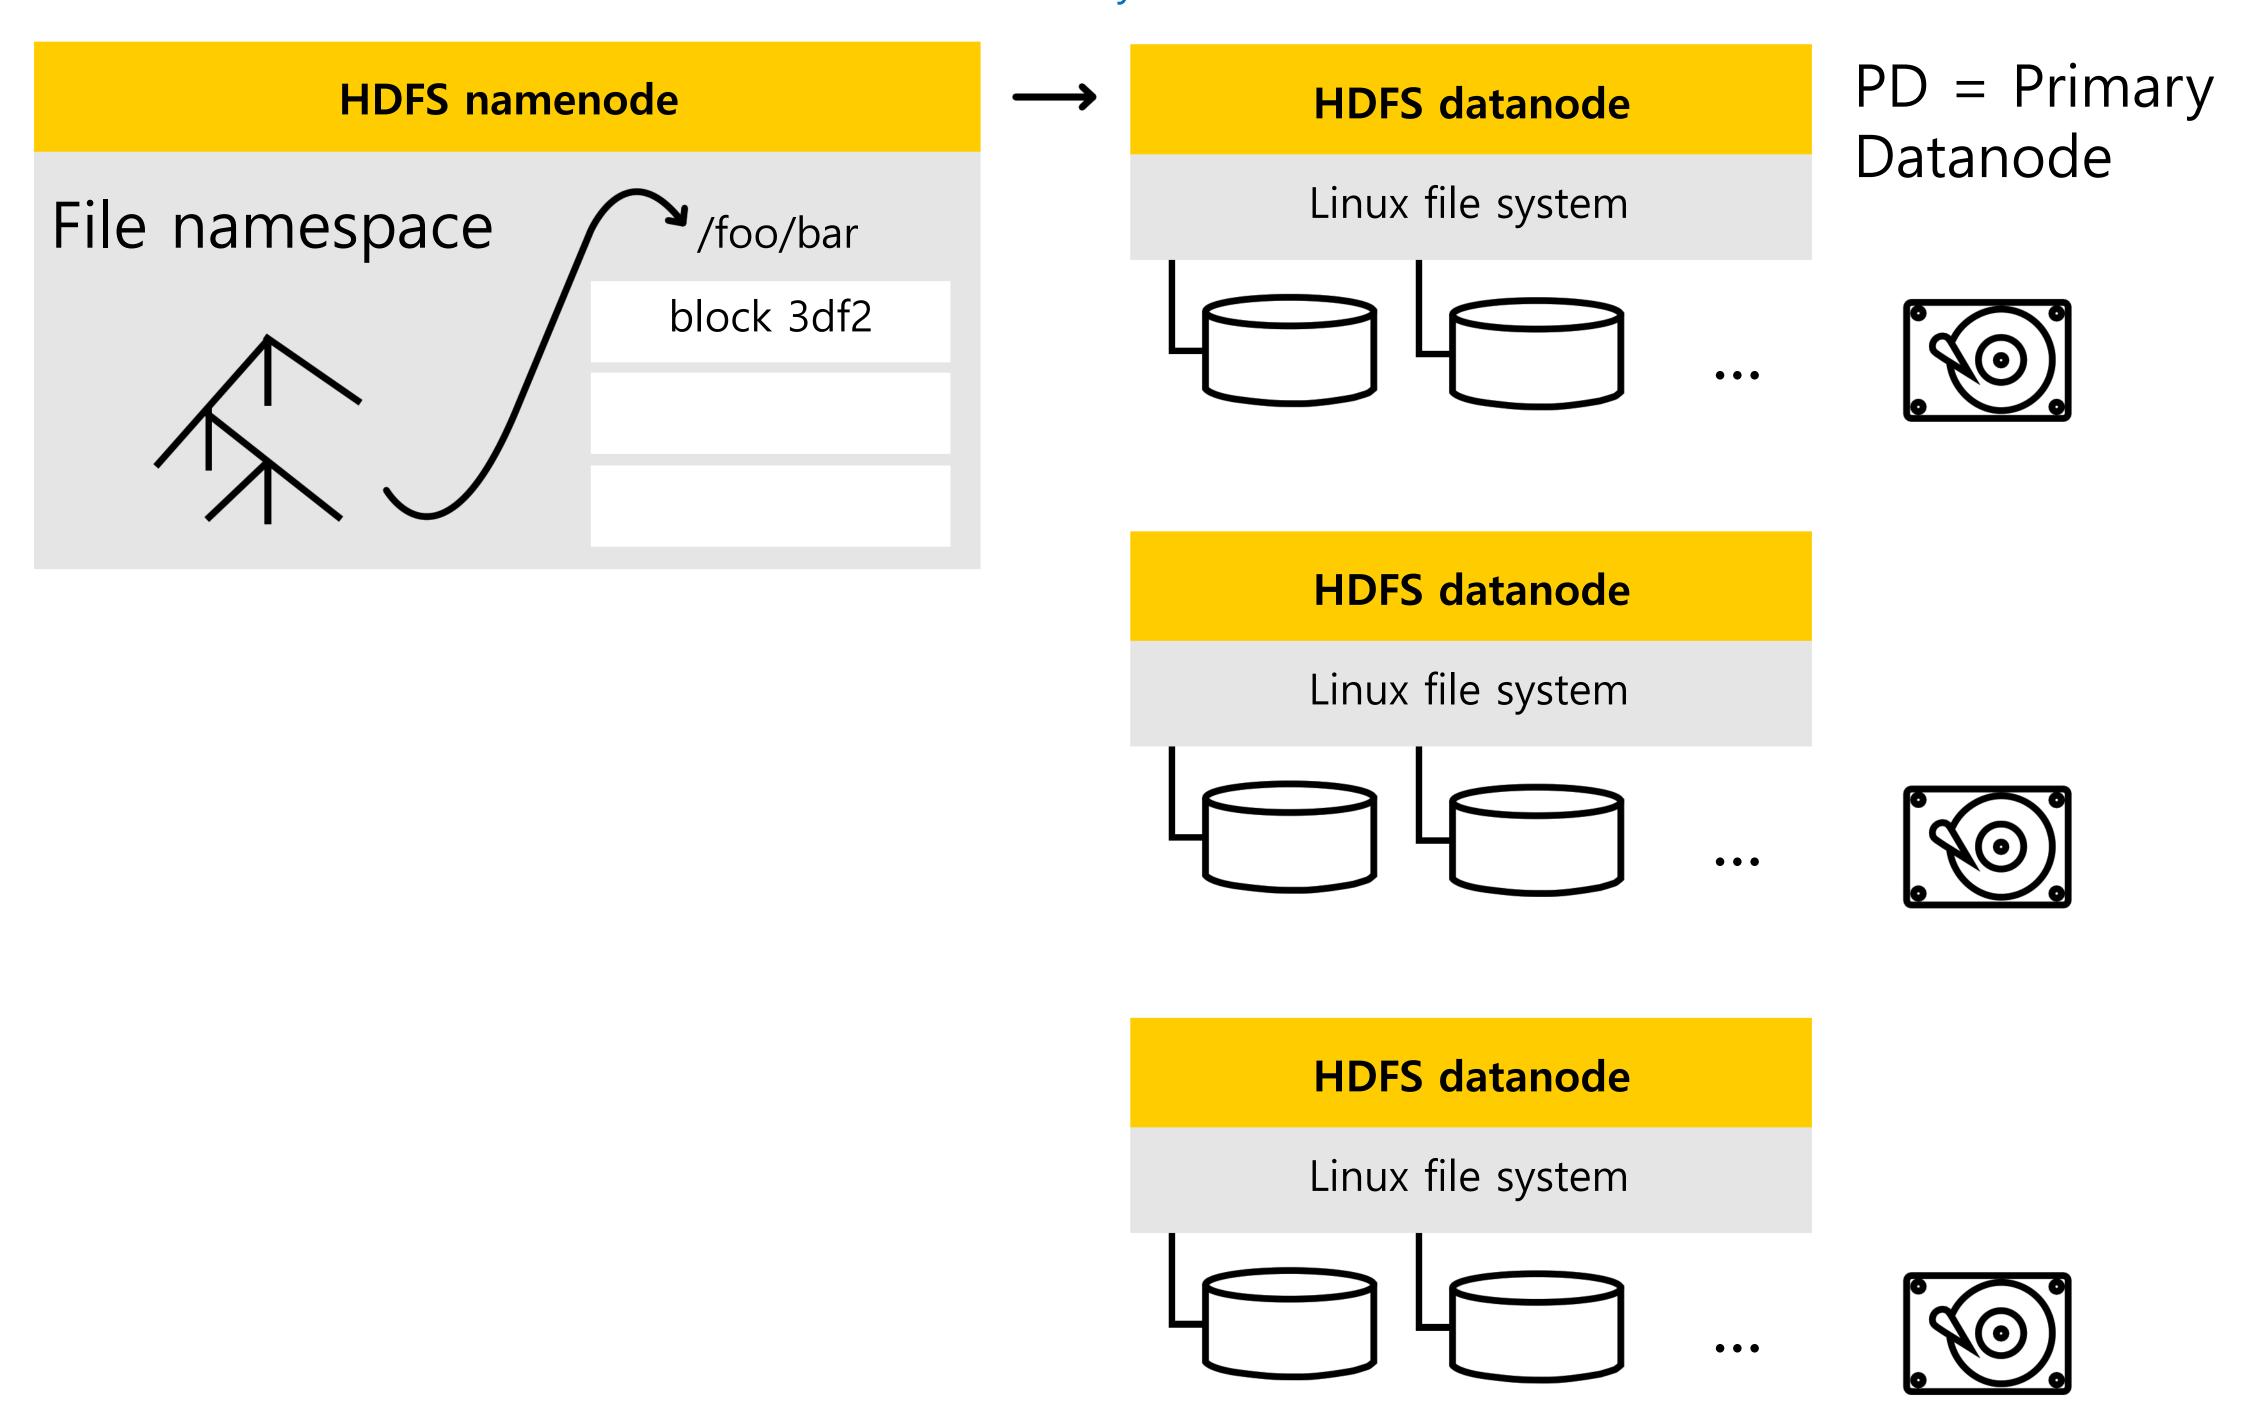
COMPLETE

#### Recovery

- > Replica Recovery
- > Block Recovery Block Recovery는 항상 Lease Recovery의 일부분이다.
- > Lease Recovery
- > Pipeline Recovery

### Block Recovery

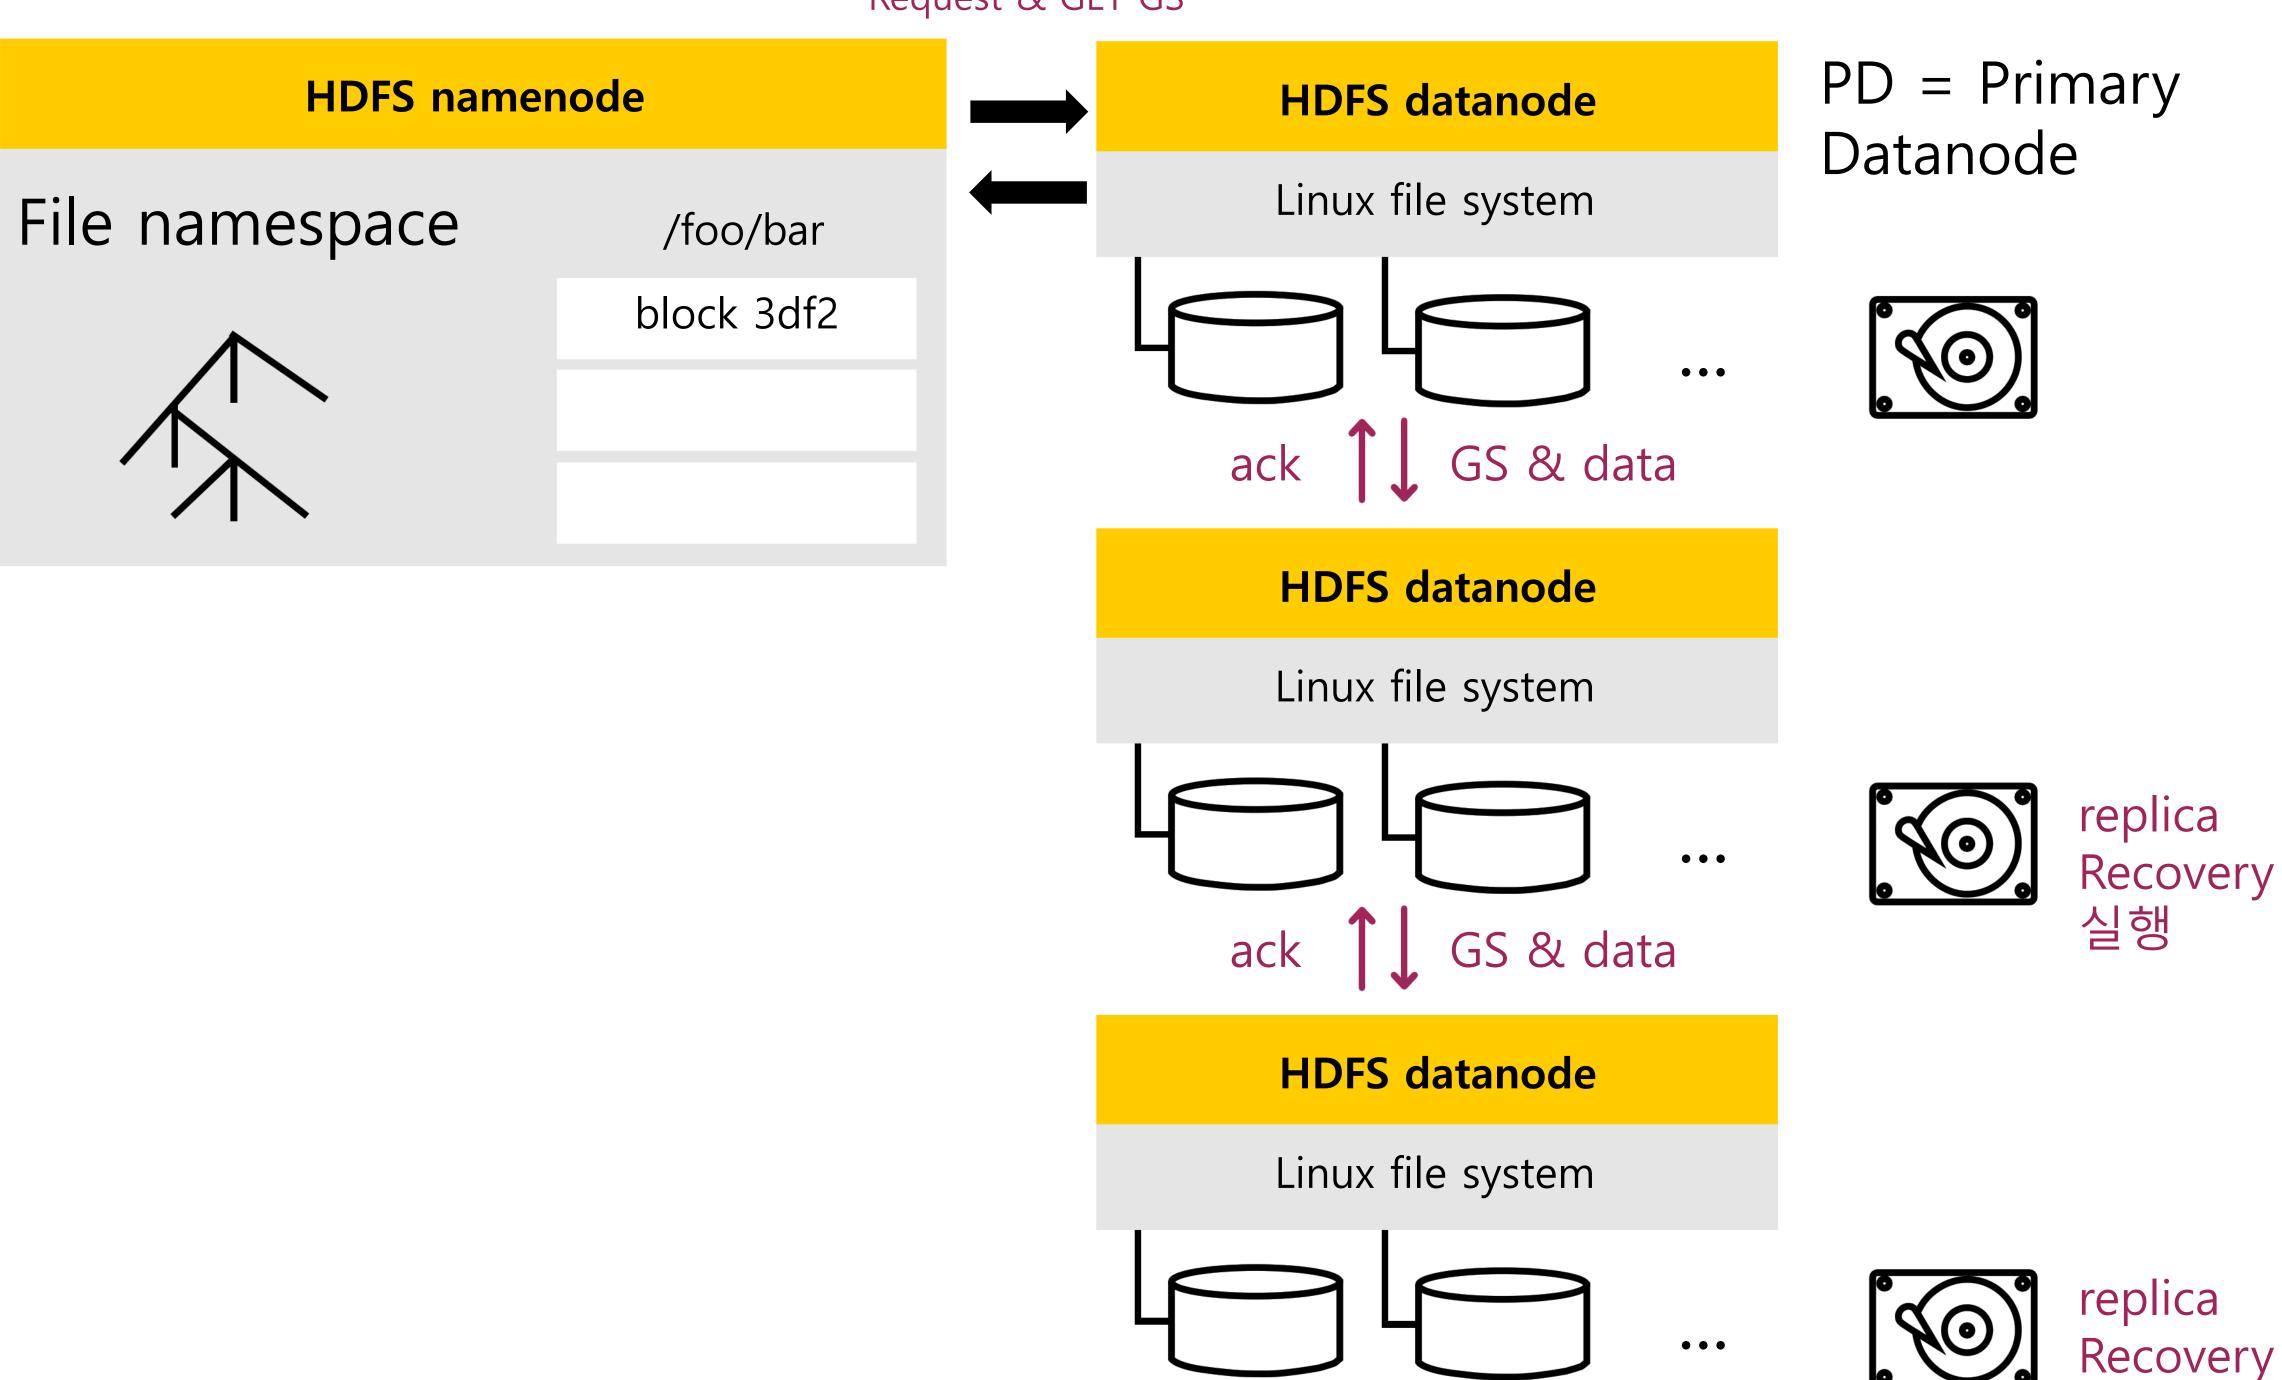
Recovery를 위해 해당 데이터를 가진 node 중 하나를 PD로 선택한다.



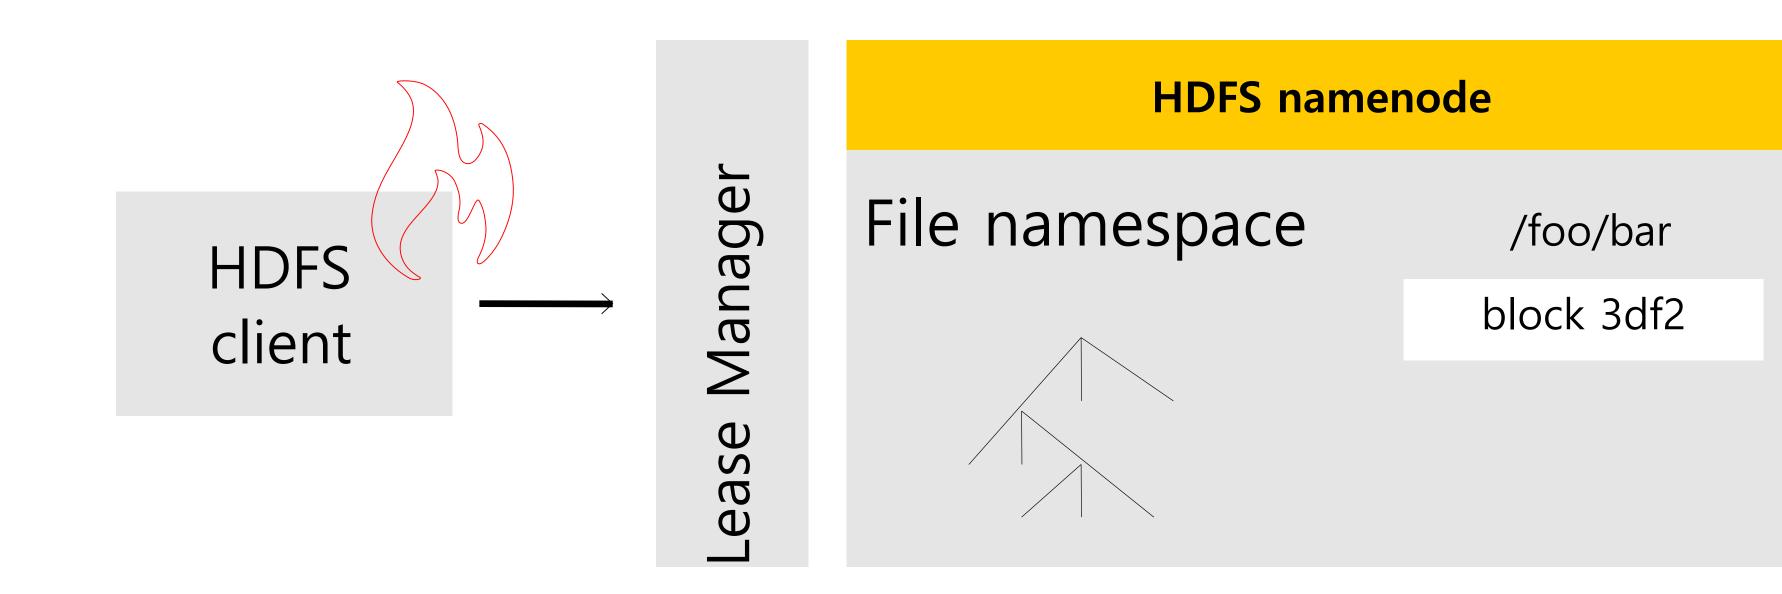
### Block Recovery

PD가 GS와 복구할 datanode의 정보를 namenode에 요청한다.

Request & GET GS







Block Recovery

```
user<sub>1</sub>, /path/1, lease (soft + hard)
user<sub>1</sub>, /path/2, lease (soft + hard)
user<sub>2</sub>, /path/3, lease (soft + hard)
user<sub>3</sub>, /path/4, lease (soft + hard)
```

• • •

Linux에서 시스템 리소스 제한 방식

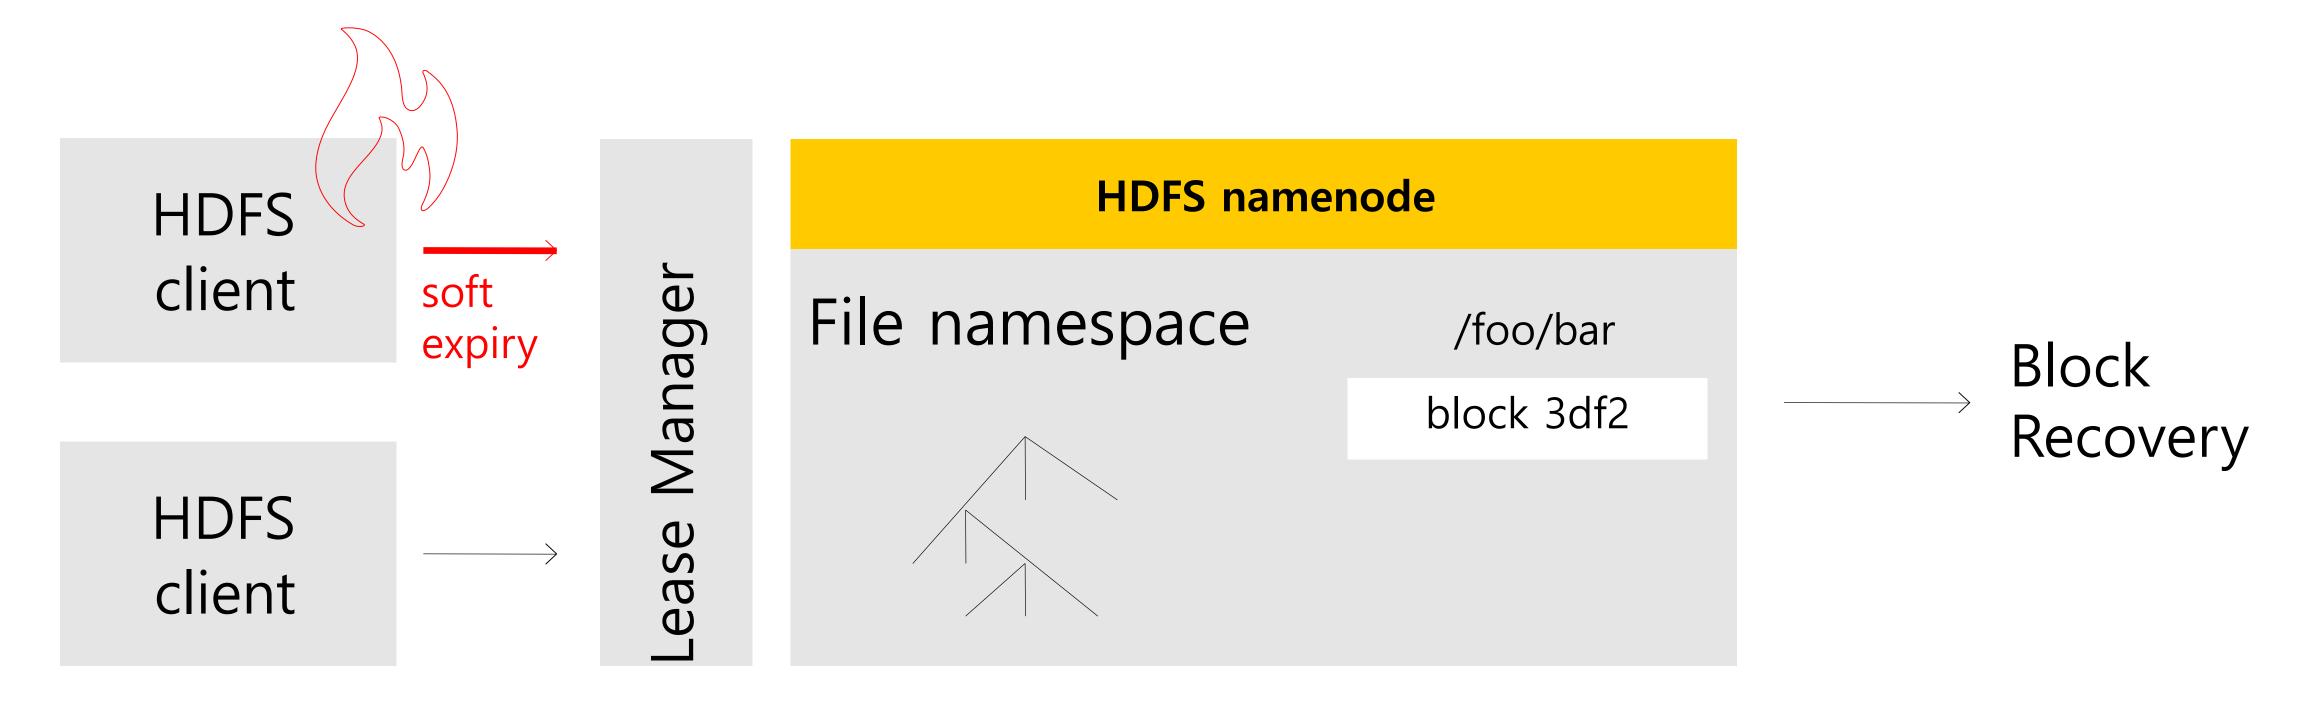
Soft limit: user가 정한 최대 실행가능한 프로세스 수

Hard limit : 관리자(root)가 정한 최대 실행가능한 프로세스 수

Lease Manager가 clients의 lease를 관리한다. Lease Manager는 soft limit(1분) and hard limit(1시간) timeout을 유

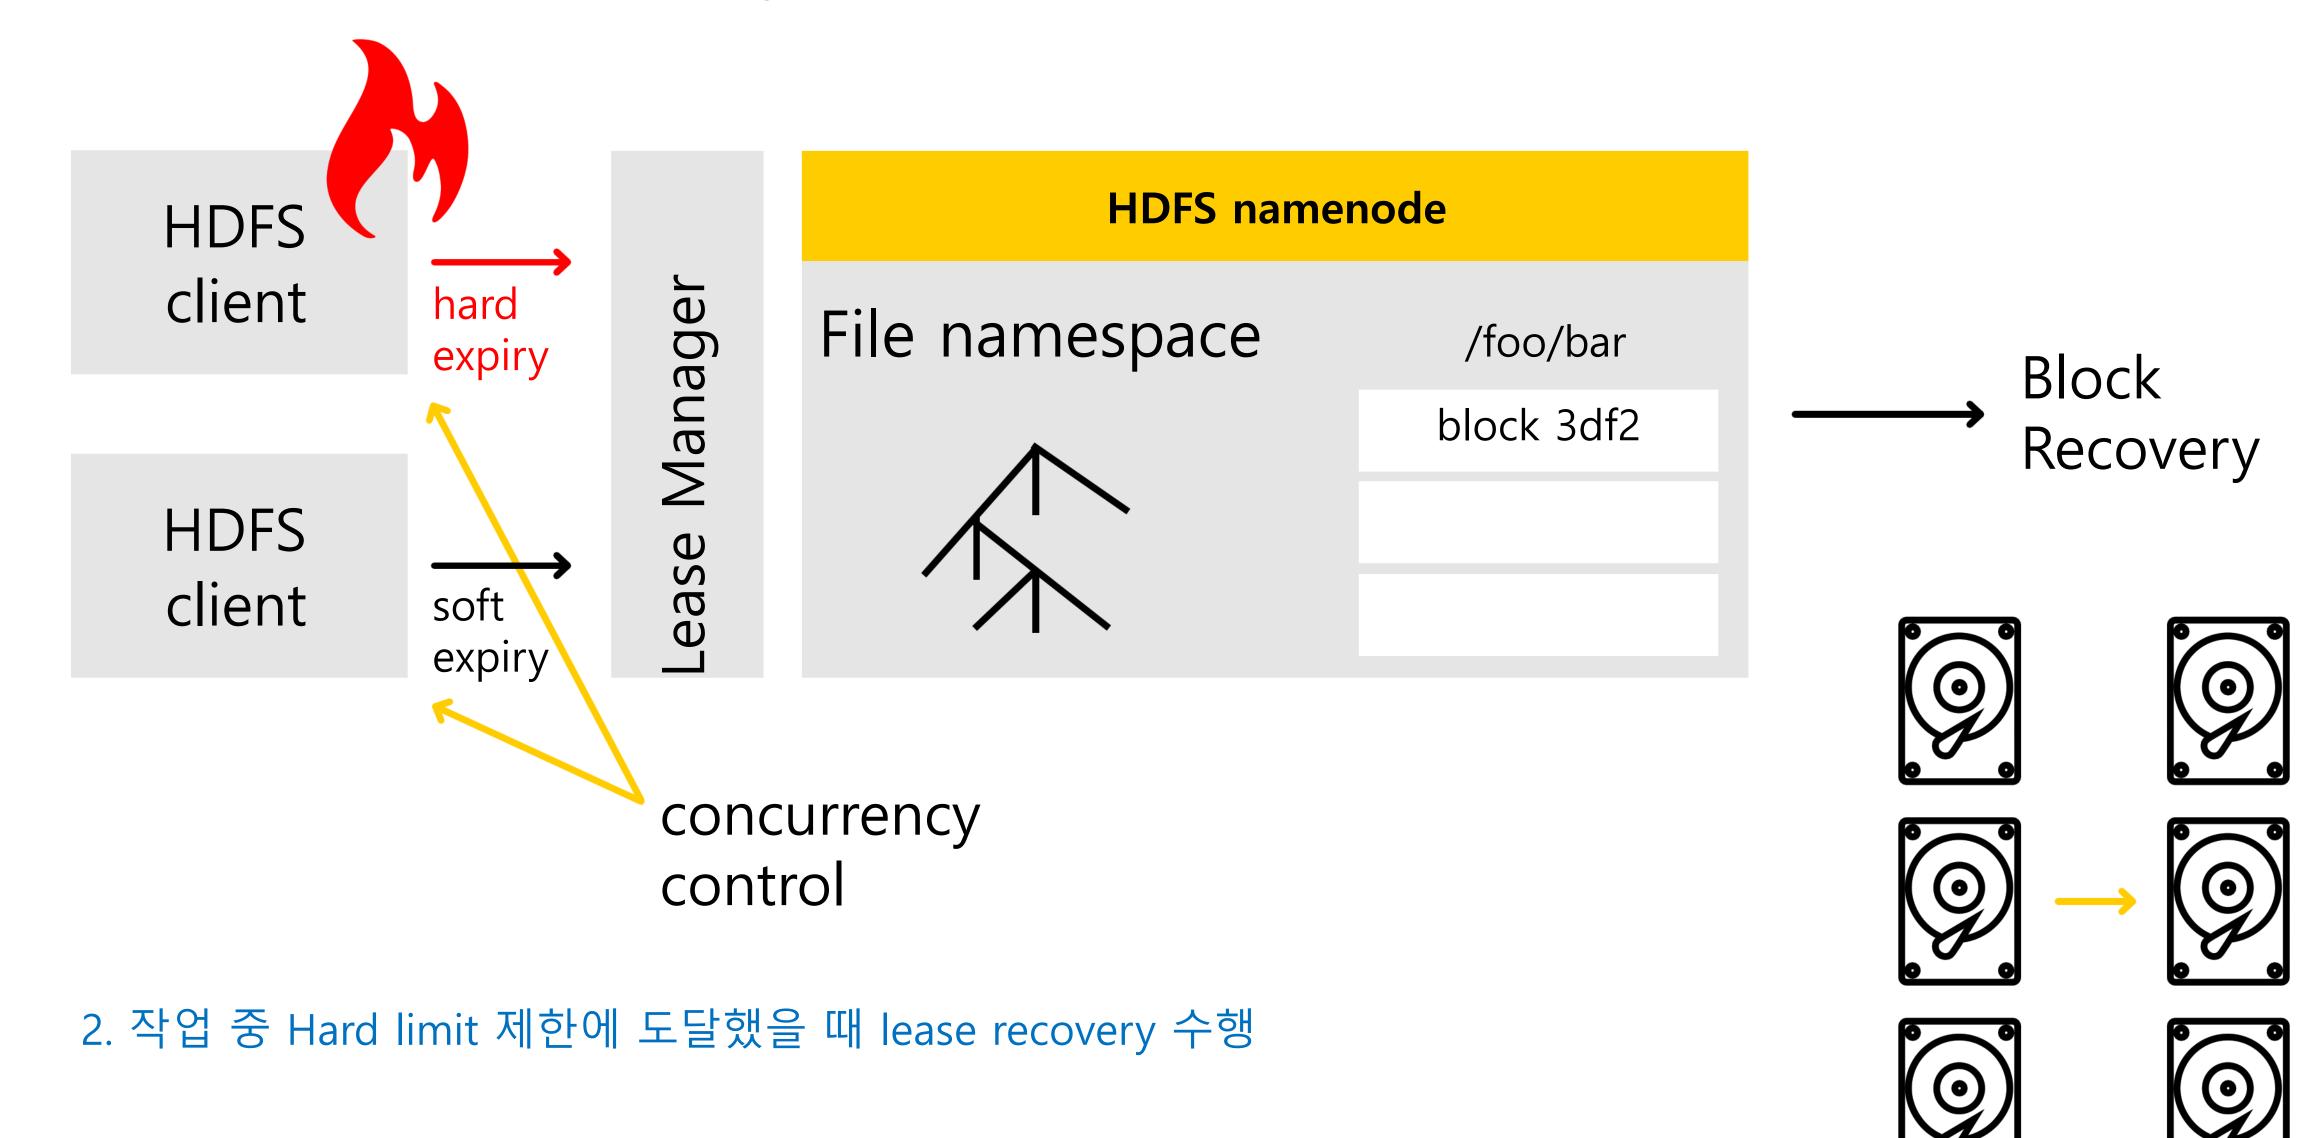
User는 해당 시간 안에 lease를 renew하거나 파일을 닫아야 한다.

Soft limit <= Hard Limit



Soft limit expiry( timeout) 의 경우 다른 client가 lease를 가져갈 수 있다.

1. 작업중인 파일에 대한 Lease가 다른 client한테 넘어갔을 때 Lease Recovery 발생



Lease Recovery 수행 중 guarantee되어야 할 것

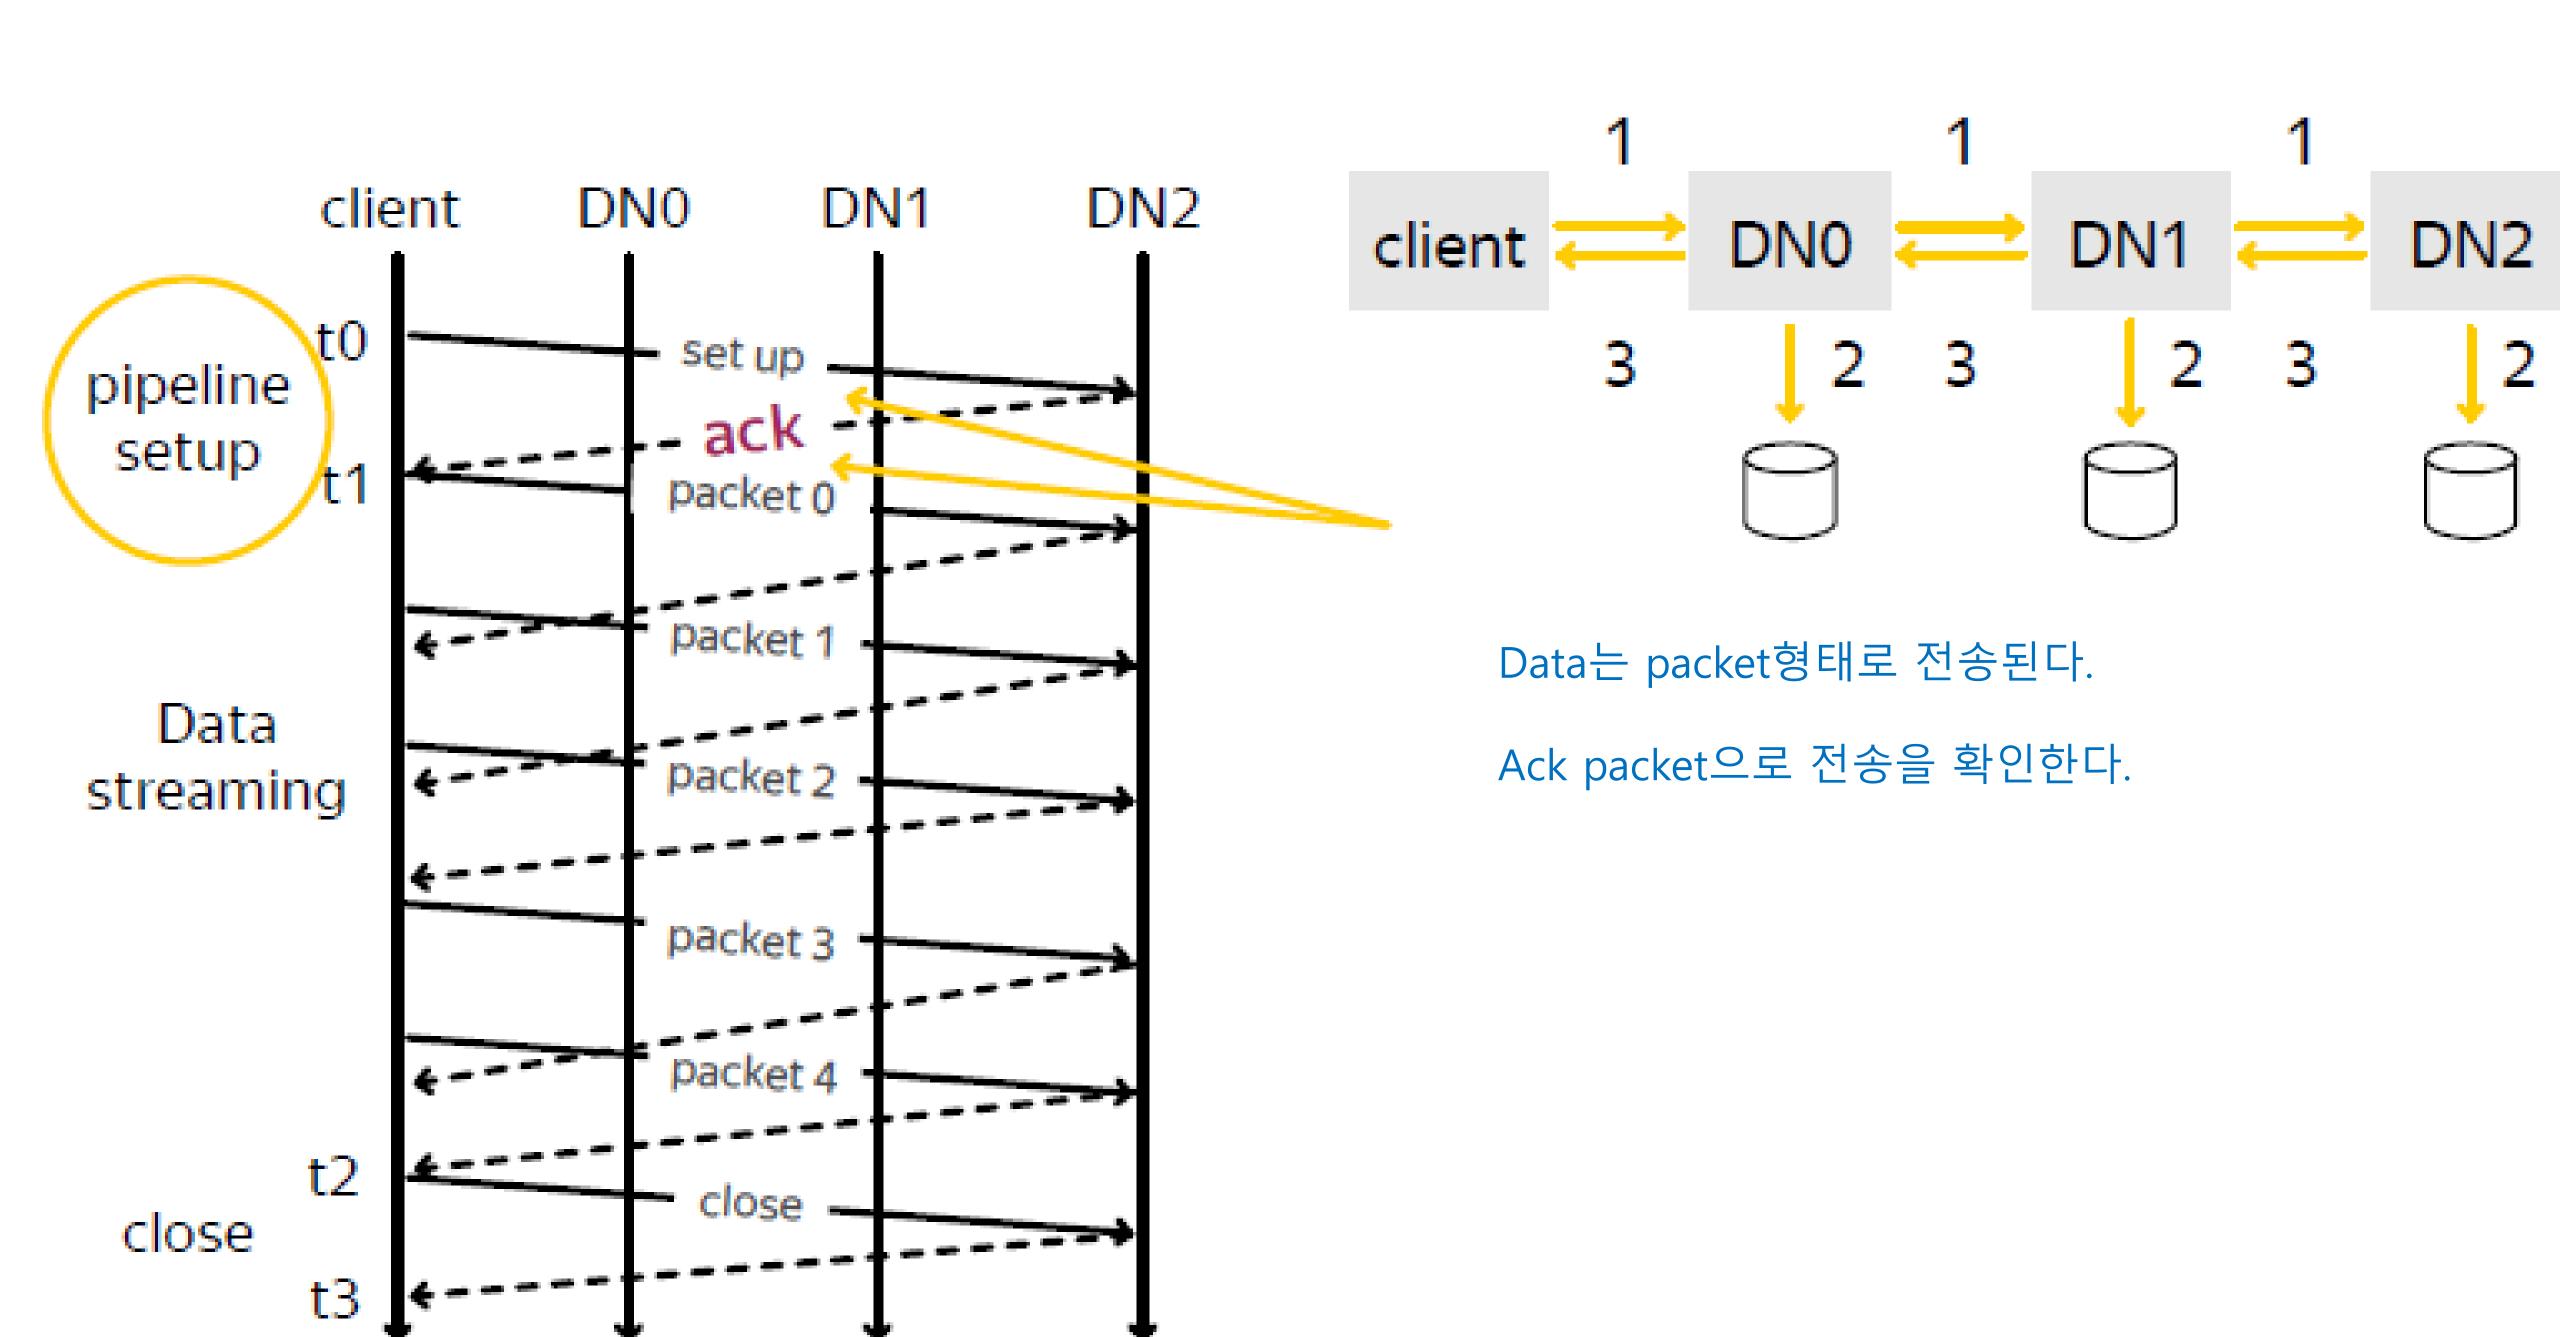
- 1.Concurrency control : 복구 중 다른 client가 write할 수 없게 한다.
- 2. Consistency guarantee : 모든 replica가 동일하게 복구되어야 한다.

consistency guarantee

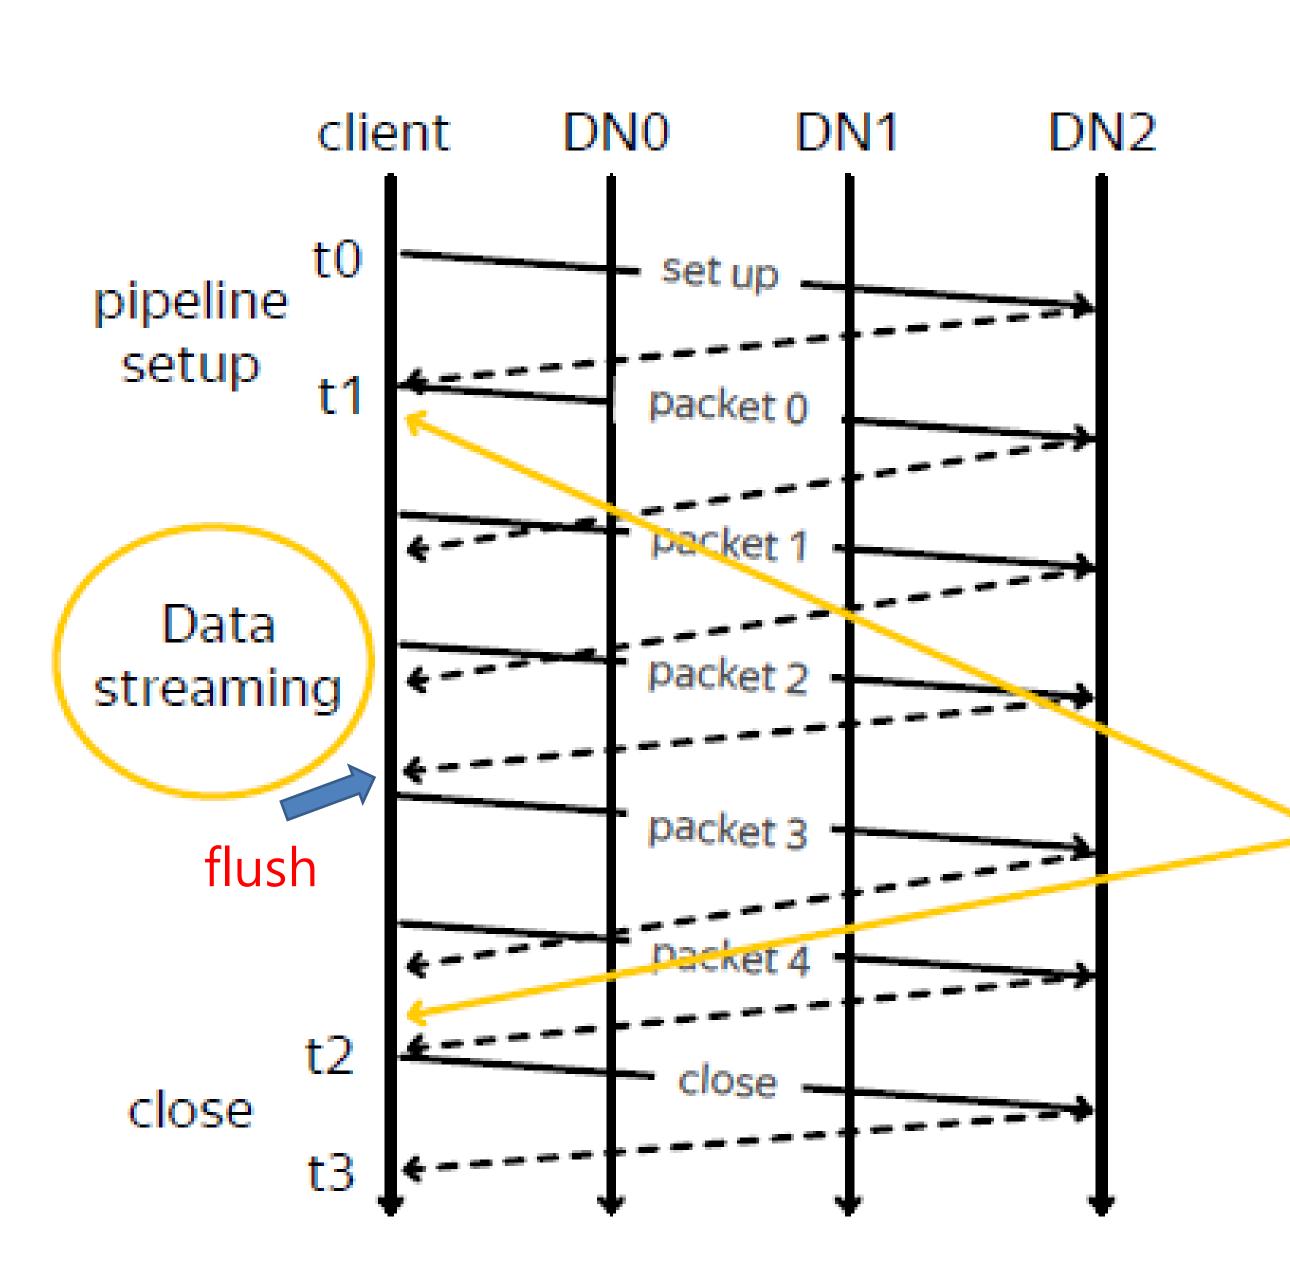
Recovery PD **HDFS** namenode **HDFS** datanode Manager Linux file system File namespace /foo/bar block 3df2 Lease **HDFS** datanode Linux file system user<sub>1</sub>, /path/1, expired lease dfs, /path/1, new lease **HDFS** datanode Recovery가 실행되면, Linux file system dfs가 super user가 되어 다른 client의 모든 요청을 거부한다.

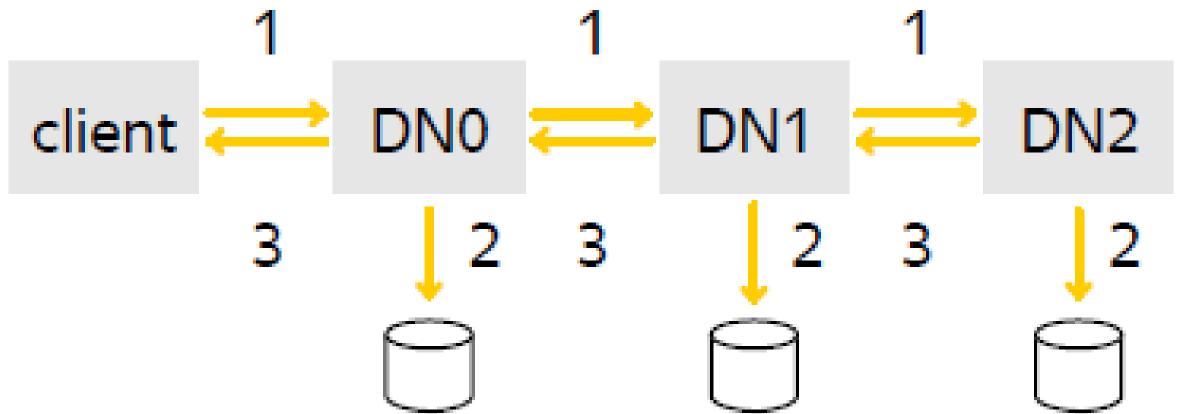
Block

### Pipeline



#### Pipeline

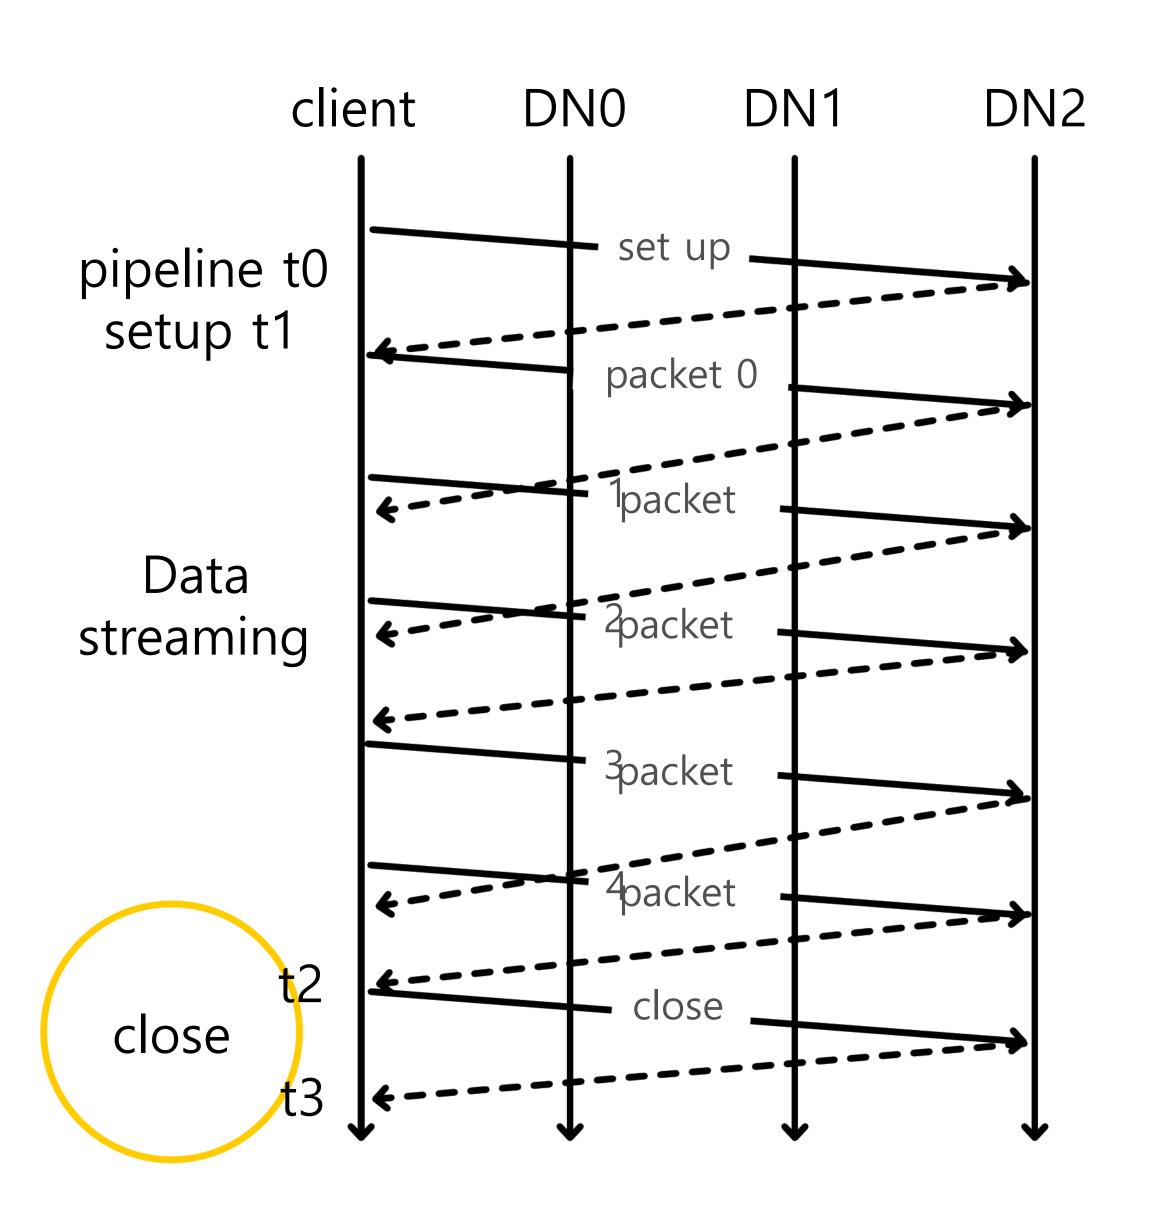


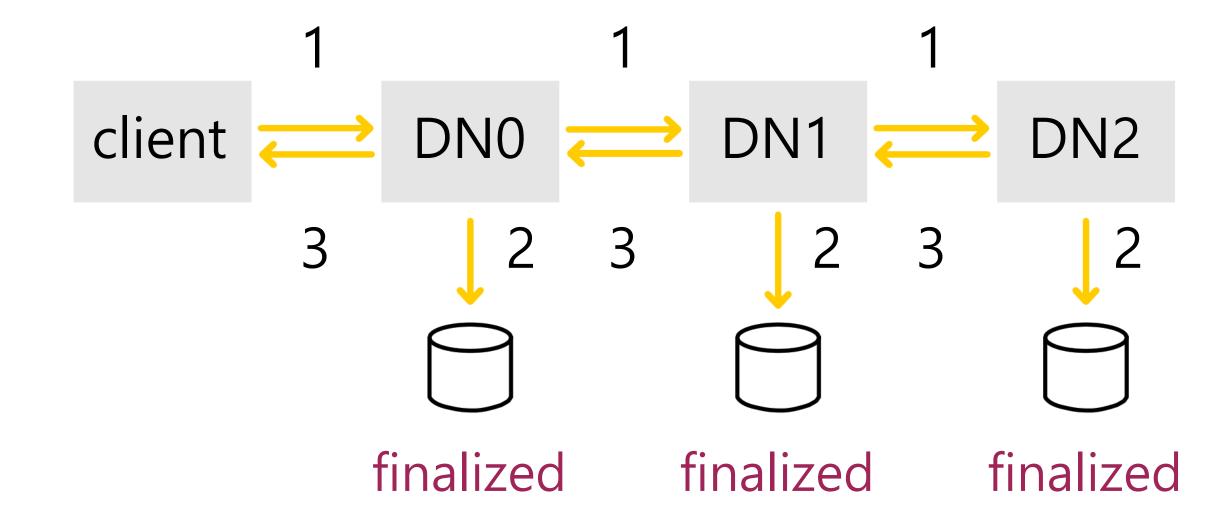


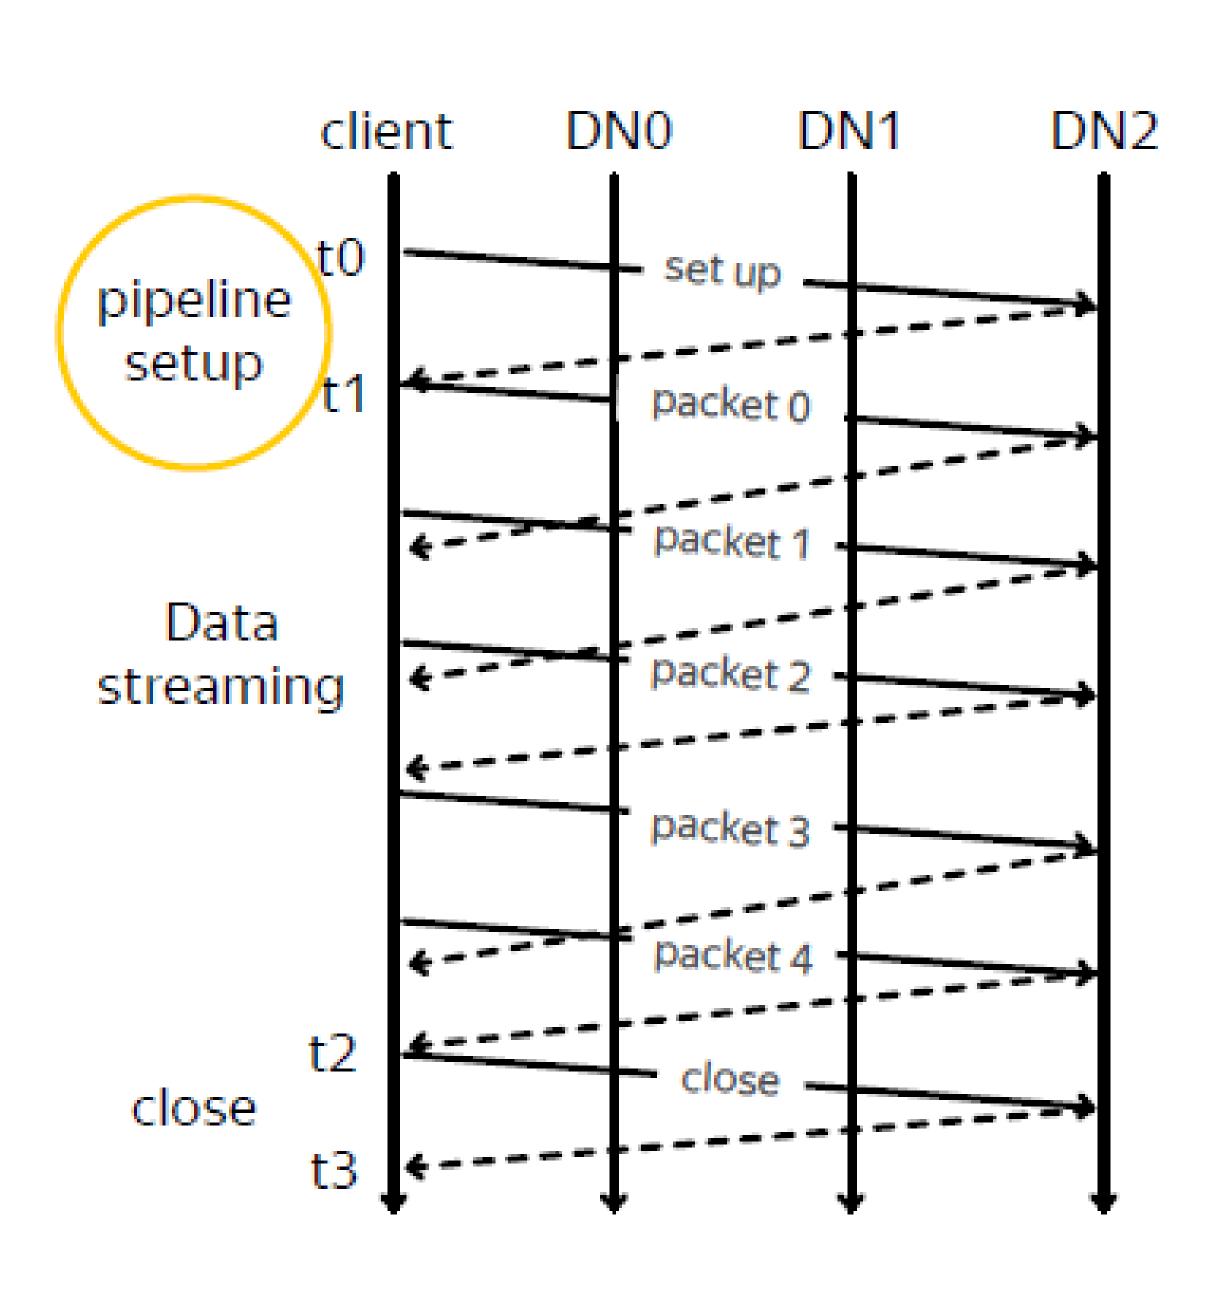
Ack 패킷이 도착하기 전에 data 패킷이 전송된다.

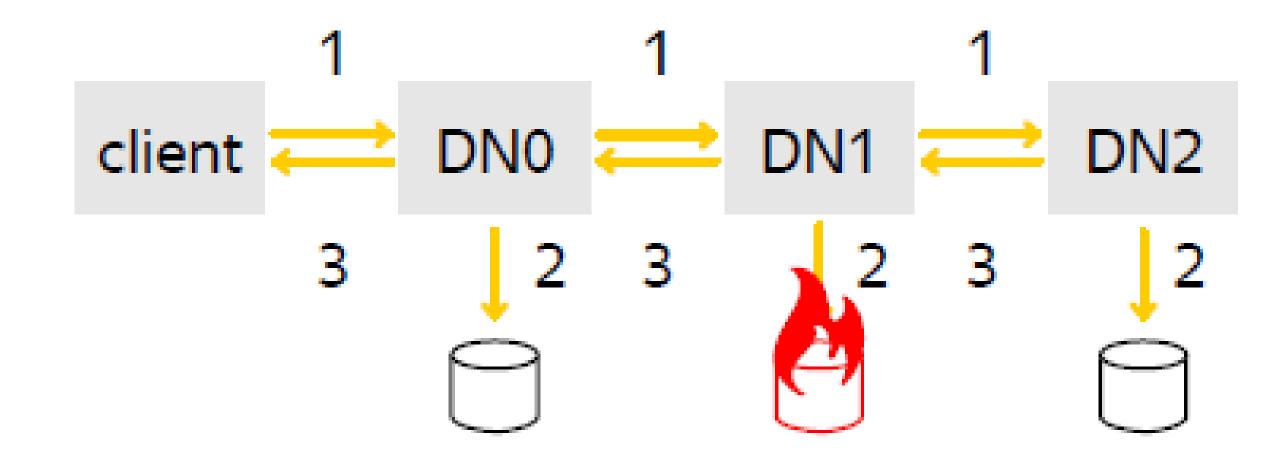
단, flush 패킷은 synchronous packet으로 데이터 동기화에 활용된다.

### Pipeline





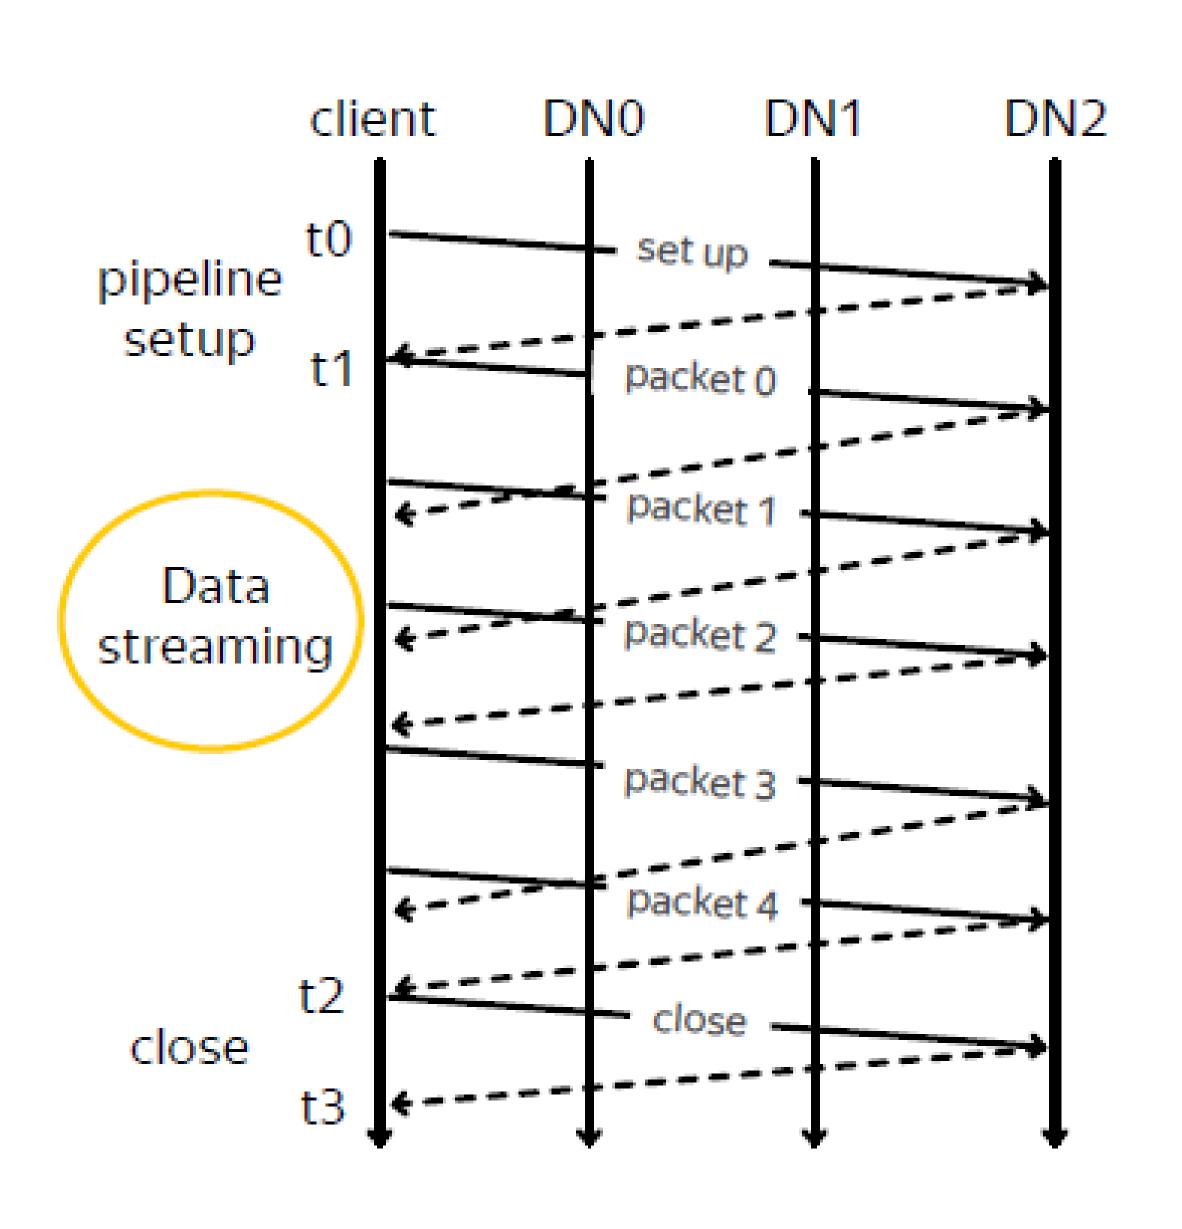


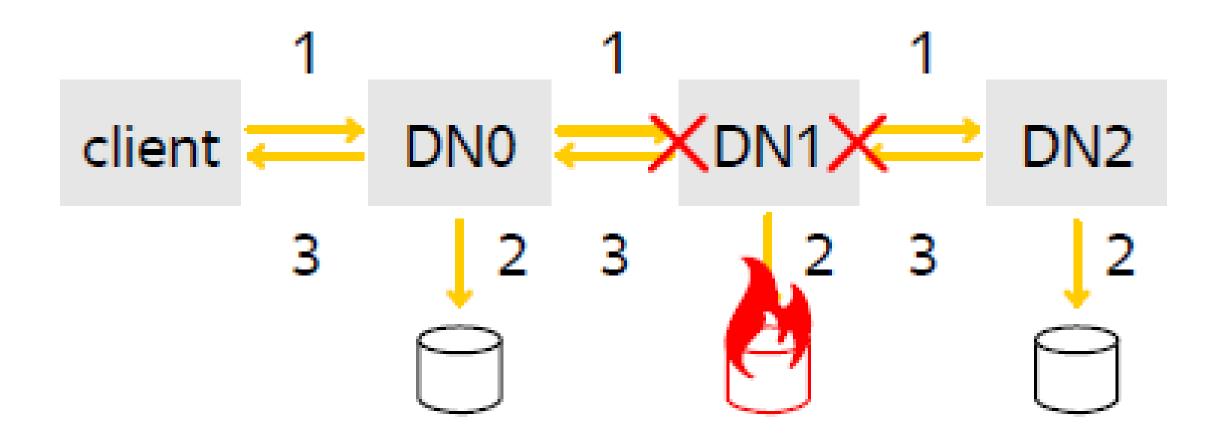


#### cases:

- 1. new file
- 2. append mode

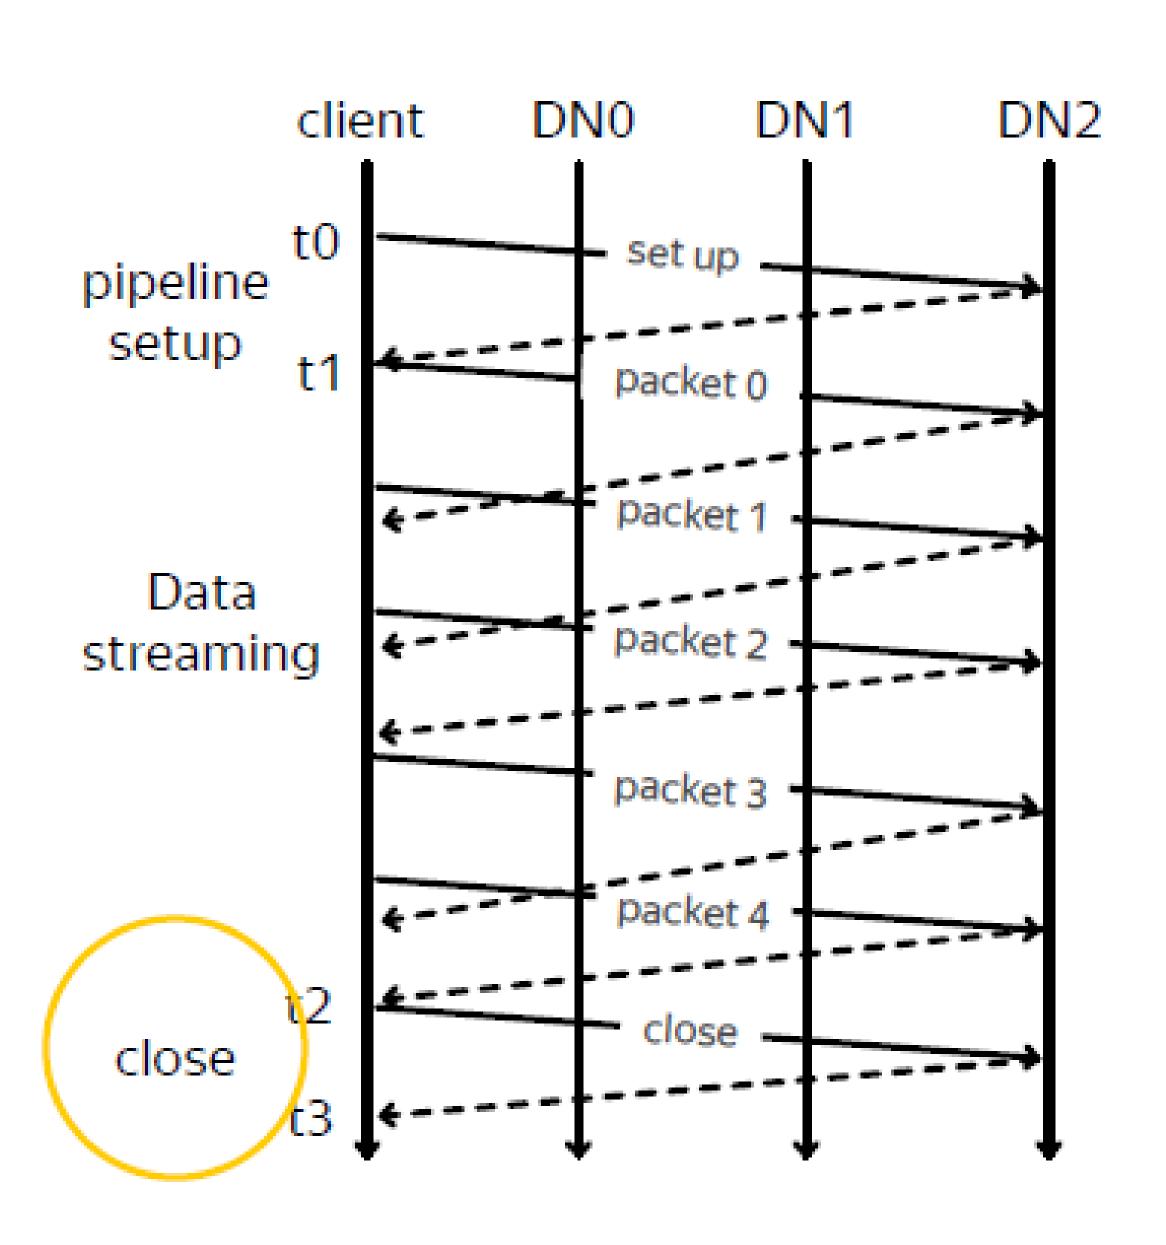
Setup 중 failure 발생 시 새로 파이프라인을 만든다.

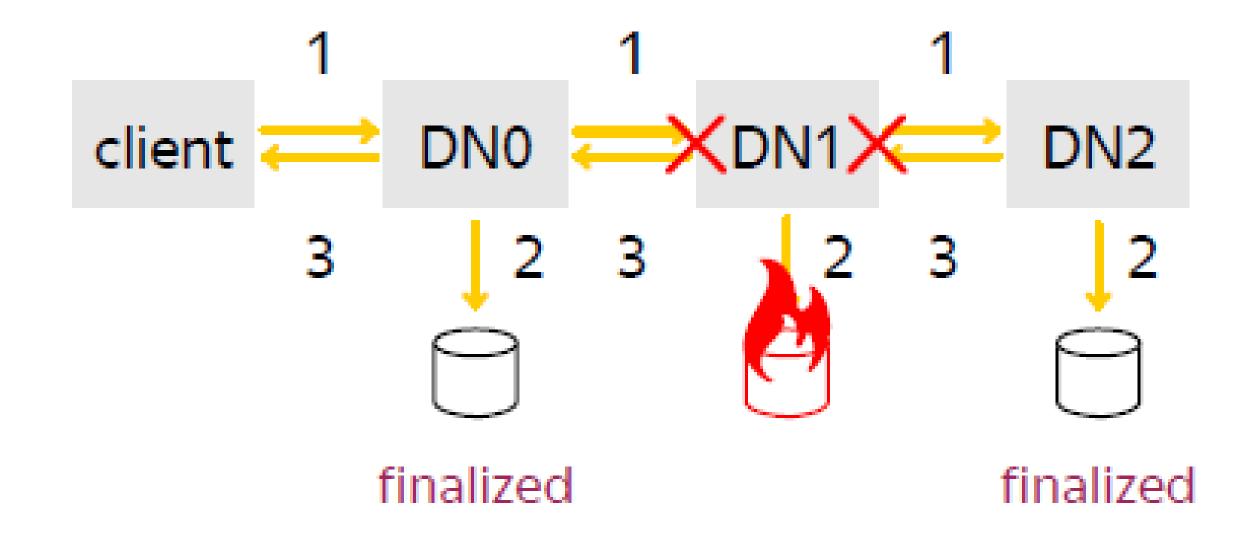




Data Streaming 중 failure가 발생하면, 패킷 전송을 중단하고 GS를 다시 받아 파이프라인을 구축한다.

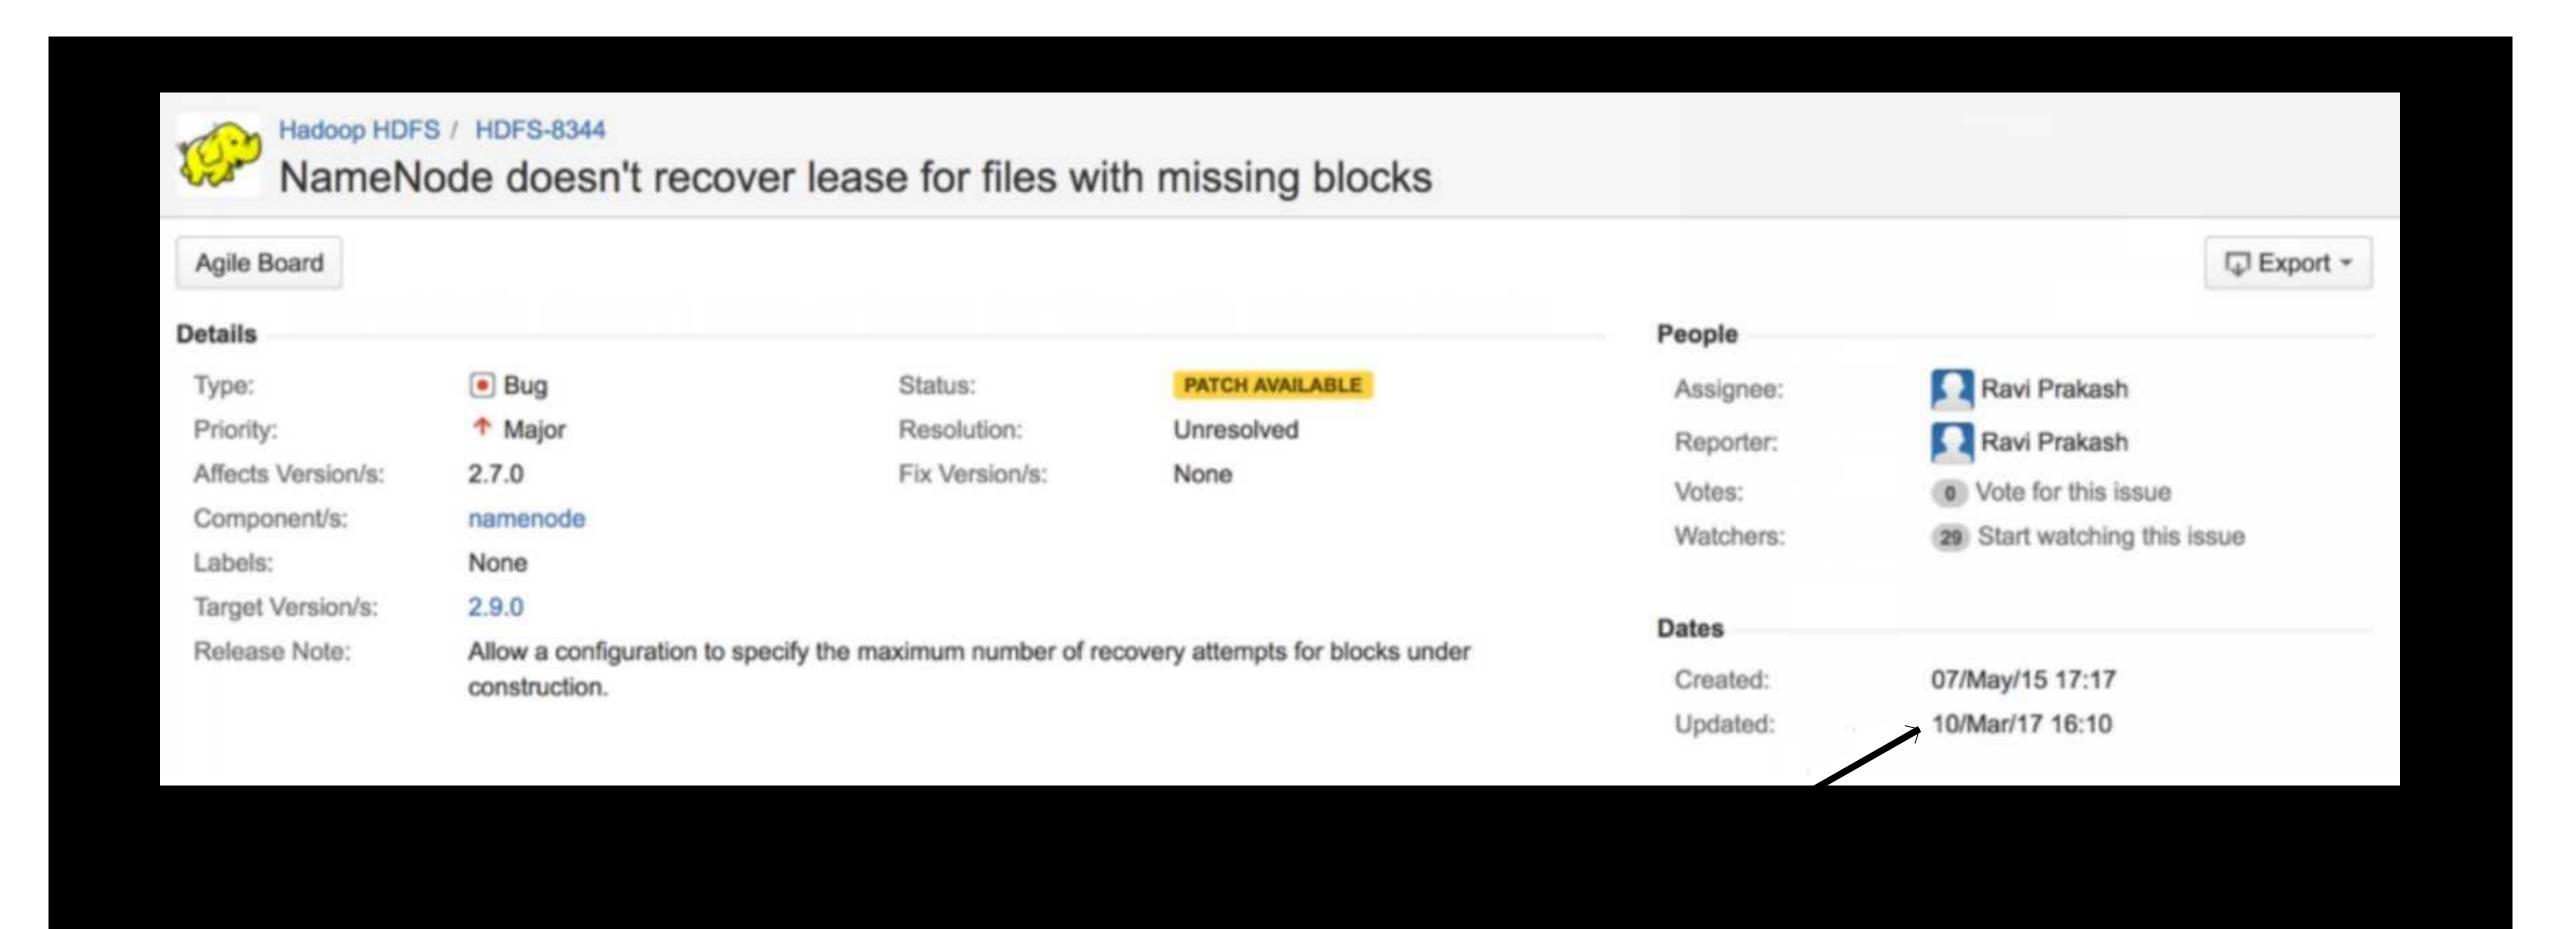
이미 전송된 패킷은 디스크에 저장되기 때문에 재구축 시 IO overhead를 줄일 수 있다.





Close 시 failure가 발생하면 GS를 다시 발급받고 파이프라인을 다시 구축한다.

데이터는 이미 디스크에 저장되어 있기 때문에 추가적인 작업은 적다.



#### Summary

- > you can draw State block and replica transition tables
- > you can identify write pipeline stages and associated recovery process
- > you can list 4 recovery processes and explain their purpose (lease recovery → block recovery → replica recovery; pipeline recovery)

# BigDATAteam